

$$L_{\psi}X$$



UNIVERSIDAD
DE GRANADA

Facultad de Ciencias y Escuela Técnica Superior de Ingeniería
Informática y Telecomunicaciones

DOBLE GRADO EN INGENIERÍA INFORMÁTICA Y MATEMÁTICAS

TRABAJO DE FIN DE GRADO

Desarrollo de aplicación para apoyo a la docencia: Agente IA conversacional como asistente para el alumnado y análisis de su uso.

Presentado por:

Gabriel Francisco Sánchez Muñoz

Curso académico 2025-2026



Desarrollo de aplicación para apoyo a la
docencia: Agente IA conversacional como
asistente para el alumnado y análisis de su
uso.

Gabriel Francisco Sánchez Muñoz

Gabriel Francisco Sánchez Muñoz *Desarrollo de aplicación para apoyo a la docencia: Agente IA conversacional como asistente para el alumnado y análisis de su uso..*

Trabajo de fin de Grado. Curso académico 2025-2026.

**Responsable de
tutorización**

Pablo García Sánchez
*Ingeniería de computadores, automática y
robótica*

Nuria Rico Castro
Estadística e investigación operativa

Doble grado en Ingeniería
Informática y Matemáticas

Facultad de Ciencias y
Escuela Técnica Superior
de Ingeniería Informática y
Telecomunicaciones

Universidad de Granada

DECLARACIÓN DE ORIGINALIDAD

D./Dña. Gabriel Francisco Sánchez Muñoz

Declaro explícitamente que el trabajo presentado como Trabajo de Fin de Grado (TFG), correspondiente al curso académico 2025-2026, es original, entendido esto en el sentido de que no he utilizado para la elaboración del trabajo fuentes sin citarlas debidamente.

En Granada a 28 de enero de 2026

Fdo: Gabriel Francisco Sánchez Muñoz

Dedicatoria (opcional)

Ver archivo preliminares/dedicatoria.tex

Agradecimientos

Agradecimientos (opcional, ver archivo preliminares/agradecimiento.tex).

Summary

An english summary of the project (around 800 and 1500 words are recommended).

File: preliminares/summary.tex

Índice general

Agradecimientos	V
Summary	VII
Introducción	XI
Notación y Simbología	XIII
I. Fundamentos matemáticos	1
1. Clustering de documentos textuales	3
1.1. Etapas de clustering de documentos textuales	3
1.2. Representación de documentos	4
1.2.1. Vector Space Model	4
2. Medidas	9
2.1. Escalares	9
2.2. Vectoriales	9
3. Métodos de clustering	11
3.1. Métodos jerárquicos	12
3.1.1. Clustering aglomerativo	12
3.1.2. Clustering divisivo	12
3.2. Métodos particionales	13
3.2.1. Clustering duro	13
3.2.2. Clustering Difuso	15
3.3. Topic modeling	22
3.3.1. Non-negative matrix factorization	22
3.4. Mezcla de modelos	36
4. Validación	37
II. Aplicación informática	39
4.1. Estado del arte	41
4.1.1. Introducción	41
4.1.2. Glosario de Términos	41
4.1.3. Línea Histórica de los ITS	43
4.1.4. ChatGPT y la Necesidad de un Chatbot Educativo Específico	44
4.1.5. Agentes LLM para la Educación	44
4.1.6. Posibles Aportaciones de los Chatbots (ITS) a la Educación	51
4.1.7. Análisis del Aprendizaje	52

Índice general

4.1.8. Problemáticas y Desafíos en la Implementación de Agentes Pedagógicos Conversacionales	53
A. Ejemplo de apéndice	55
Glosario	57
Bibliografía	59

Introducción

De acuerdo con la comisión de grado, el TFG debe incluir una introducción en la que se describan claramente los objetivos previstos inicialmente en la propuesta de TFG, indicando si han sido o no alcanzados, los antecedentes importantes para el desarrollo, los resultados obtenidos, en su caso y las principales fuentes consultadas.

Ver archivo preliminares/introduccion.tex

Notación y Simbología

A lo largo de este trabajo se utilizará la siguiente notación matemática, salvo que se especifique lo contrario en un contexto particular.

Conjuntos e Índices

$\mathbb{R}$	Conjunto de los números reales.
$\mathbb{R}^n$	Espacio vectorial euclídeo de dimensión n .
$\mathcal{D}$	Corpus de documentos, $\mathcal{D} = \{d_1, \dots, d_N\}$.
$\mathcal{V}$	Vocabulario de términos únicos.
Ω	Universo base para subconjuntos difusos
N	Número total de documentos en el corpus.
V	Tamaño del vocabulario (número total de términos únicos).
K	Número de clústeres (o grupos) a identificar.

Álgebra Lineal y Representación

$\vec{x}_i$	Representación vectorial del documento i . Normalmente $\vec{x}_i \in \mathbb{R}^V$.
$\vec{x}_i(l)$	Coordenada l -ésima del vector-documento i
X	Matriz de datos (Término-Documento o Documento-Término).
$\ \cdot\ $	Norma euclídea (norma ℓ_2) de un vector.
$\ \cdot\ _F$	Norma de Frobenius de una matriz.
$A_{ij}, [A]_{ij}$	Elemento de la fila i -ésima y columna j -ésima de la matriz A

Clustering y Optimización

C	Conjunto de centroides, $C = \{c_1, \dots, c_K\}$.
c_j	Centroide (o prototipo) del clúster j .
U	Matriz de pertenencia (Fuzzy Partition Matrix), donde $u_{ij} \in [0, 1]$.
m	Exponente de difusividad (fuzzifier) en el algoritmo FCM ($m > 1$).
J_m	Función objetivo del algoritmo FCM.
$d(x, y)$	Función de distancia entre dos vectores x e y .
$\mu_A(x)$	Función de pertenencia del elemento x al conjunto difuso A .

Parte I.

Fundamentos matemáticos

1. Clustering de documentos textuales

La generación masiva de datos por parte de personas y sistemas automáticos es una característica que define la era actual. Según las estimaciones de Reinsel et al. [62], gran parte de esta información consiste en documentos textuales, tales como blogs, publicaciones en redes sociales o artículos académicos. La necesidad de procesar y ordenar esta información para extraer valor de ella es cada día más evidente.

Tal y como sostienen autores de referencia como Aggarwal [3] y Manning et al. [48], el *clustering* de documentos se ha consolidado como una de las técnicas fundamentales en la minería de texto y la recuperación de información. Su propósito principal es organizar colecciones de documentos de manera no supervisada, construyendo grupos donde los textos presentan una alta similitud semántica entre sí, diferenciándose claramente de los documentos de otros grupos.

Esta técnica es especialmente valiosa cuando no se dispone de etiquetas previas. Como indica Manning [48], el clustering permite descubrir patrones y estructuras temáticas latentes en los datos. Sus aplicaciones son vastas y, según demuestran trabajos clásicos como el de Allan et al. [5], abarcan desde la organización automática de noticias hasta la mejora de los sistemas de recuperación de información.

1.1. Etapas de clustering de documentos textuales

Dada la naturaleza no estructurada de los datos textuales, no es posible aplicar algoritmos de agrupamiento de forma directa. Para garantizar la coherencia y validez de los resultados, resulta imperativo implementar un flujo de trabajo riguroso. Siguiendo la estructura metodológica descrita por Aggarwal y Zhai [3], este proceso de transformación y análisis suele articularse en las siguientes etapas secuenciales:

1. **Preprocesamiento.** En esta fase se prepara el texto para que pueda ser representado adecuadamente. Entre otras tareas, es necesario eliminar «ruido», como palabras que no aportan información semántica (*stop-words*), caracteres no alfanuméricos, dígitos, etc.
2. **Representación.** Los documentos son, en origen, datos no estructurados. Para aplicar métodos de clustering es necesario transformarlos a una representación matemática estructurada que mantenga la identidad semántica del documento.
3. **Reducción de la dimensión.** Frecuentemente, los documentos terminan siendo representados por vectores de dimensión muy alta, lo que puede causar problemas de coste computacional y almacenamiento (la maldición de la dimensionalidad). Por ello, se suele asumir cierta pérdida de información aplicando técnicas de proyección latente, como el análisis semántico latente (LSA) introducido por Deerwester et al. [24] o PCA.
4. **Clustering.** La fase fundamental es la aplicación del algoritmo de agrupamiento. La elección depende de múltiples factores, como la forma esperada de los clústeres, el

1. Clustering de documentos textuales

tipo de agrupación deseada (jerárquica, particional, basada en modelos de distribución, etc.) o la capacidad de incluir nuevos datos a posteriori. Para elegir el método adecuado es imprescindible comprender sus fundamentos matemáticos.

5. **Evaluación.** El paso final, donde se comprueba si el resultado es satisfactorio o si es necesario iterar sobre alguna de las fases anteriores.

1.2. Representación de documentos

Para aplicar algoritmos de clustering es imprescindible transformar los documentos textuales en una representación numérica. En este sentido, se adopta el Modelo de Espacio Vectorial establecido originalmente por Salton et al. [64]. Sin embargo, definir qué constituye un «documento» y cómo representarlo adecuadamente no es una tarea trivial, ya que implica estructurar información inherentemente ambigua.

1.2.1. Vector Space Model

Un texto no es solo un conjunto de palabras, sino una sucesión finita y ordenada de las mismas, donde el significado de cada palabra depende de su entorno. Como advierten Manning et al. [48], los modelos más simples, como la «bolsa de palabras» (*Bag of Words*), ignoran el orden y la estructura sintáctica, lo que puede llevar a una pérdida de significado.

Es crucial no solo saber qué palabras aparecen, sino cuántas veces lo hacen. La frecuencia de una palabra es un indicador de su relevancia en el documento, por lo que modelar el texto como un simple conjunto (presencia/ausencia) suele ser insuficiente.

A continuación, se establecen las definiciones formales necesarias para construir una representación robusta, comenzando por la unidad básica: el documento.

Definición 1.1. (Documento) Siguiendo la formalización de Salton [64], un documento se define como un vector $d \in \mathbb{R}^V$ donde cada coordenada k representa la frecuencia un término t_k perteneciente a un conjunto de términos posibles o vocabulario $\mathcal{V}$, con tamaño V [64].

Es decir, si tenemos el vocabulario $\mathcal{V} = \{\text{«uno»}, \text{«más»}, \text{«dos»}, \text{«tres»}\}$, el documento «Uno más uno es dos» se representaría como $d = (1, 1, 1, 0)$.

Nota 1.2. Aunque se define un vocabulario como conjunto, a la hora de representar uno o más documentos es necesario dotarlo con un orden arbitrario.

Definición 1.3. (Corpus). Conjunto de documentos con los que se va a trabajar, denotado como $\mathcal{D} = \{d_1, d_2, \dots, d_N\}$, donde N es el número total de documentos.

En cuanto al vocabulario utilizado para representar los documentos, podemos distinguir dos tipos:

Definición 1.4. (Vocabulario interno). Es el conjunto de todos los términos únicos presentes en los documentos del corpus $\mathcal{D}$, denotado como $\mathcal{V} = \{w_1, w_2, \dots, w_V\}$, donde V es el número total de términos.

Definición 1.5. (Vocabulario externo). Es el conjunto de términos únicos presentes en una fuente de conocimiento externa $\mathcal{D}_E$, denotado como $\mathcal{V}_E$, cuyo cardinal puede diferir del vocabulario interno y suele ser mayor.

Ejemplo ilustrativo. Tomando como referencia el corpus $\mathcal{D}$ que se presentará en la Tabla 1.1, podemos concretar esta diferencia:

- **Vocabulario Interno ($\mathcal{V}$):** Está limitado estrictamente a los 13 términos que aparecen en nuestros documentos:

$$\mathcal{V} = \{\text{clustering, de, diez, documentos, \dots, tfg, trabajo, un}\}$$

Cualquier palabra fuera de esta lista es invisible para un modelo basado solo en este corpus.

- **Vocabulario Externo ($\mathcal{V}_E$):** Si utilizáramos un modelo de lenguaje externo para enriquecer el análisis, este vocabulario contendría miles de palabras adicionales:

$$\mathcal{V}_E = \{\dots, \text{algoritmo, computación, universidad, \dots}\}$$

Esta distinción es crítica. Si un documento nuevo contiene la palabra «algoritmo», el vocabulario interno no podrá representarla (problema de *Out-Of-Vocabulary*), mientras que un enfoque con vocabulario externo sí podría capturar su semántica.

Sin embargo, recordemos que un documento es un vector con dimensión igual al cardinal del vocabulario. Es decir, un documento representado con un vocabulario externo extenso tendrá más dimensiones.

Con las definiciones anteriores, y basándonos en la literatura estándar [48], podemos definir una pieza clave para la representación y clustering de texto: La matriz Documento-Término.

Definición 1.6. (Matriz Documento-Término). Sea $X \in \mathbb{R}^{V \times N}$, donde V es el tamaño del vocabulario y N el tamaño del corpus. Cada elemento x_{td} de la matriz corresponde a un peso w_{td} que cuantifica la importancia del término t en el documento d .

El valor exacto de w_{td} depende del esquema de pesado seleccionado.

Esquema 1: Frecuencia Absoluta

El enfoque más intuitivo es definir el peso como el número de veces que aparece el término en el documento

$$w_{td} = \text{tf}(t, d)$$

donde $\text{tf}(t, d)$ es el conteo simple del término.

Como se aprecia en el ejemplo de la Tabla 1.1, esta representación tiene diferentes limitaciones. Por ejemplo, la pérdida del contexto y de la dependencia secuencial de las palabras. Las frases «Solo yo entiendo este problema» y «Yo solo entiendo este problema» tienen un significado diferente, pero su representación vectorial en este modelo es idéntica. Técnicas más recientes como la representación bitérmino [79] o el uso de *embeddings* con SBERT [61] mitigan este problema capturando el contexto semántico.

Adicionalmente, en la matriz de frecuencias simple, todas las palabras tienen el mismo peso inicial. Sin embargo, términos muy comunes (como artículos o preposiciones) suelen aportar poca información discriminante.

1. Clustering de documentos textuales

Tabla 1.1.: Ejemplo de Matriz Término-Documento con frecuencias absolutas como pesos.

	Documento 1 (d_1)	Documento 2 (d_2)	Documento 3 (d_3)
clustering	0	1	0
de	0	1	0
diez	1	0	1
documentos	0	1	0
el	0	1	0
es	0	1	0
este	1	0	1
interesante	0	1	0
merece	1	0	1
se	1	0	0
tfg	1	0	0
trabajo	0	0	1
un	1	0	1

Corpus ($\mathcal{D}$):

d_1 : "Este TFG se merece un diez"

d_2 : "El clustering de documentos es interesante"

d_3 : "Este trabajo merece un diez"

Vocabulario ($\mathcal{V}$):

{clustering, de, diez, documentos, el, es, este, interesante, merece, se, tfg, trabajo, un}

Esquema 2: TF-IDF

Para solucionar esto, se introduce una ponderación estadística.

Definición 1.7. (TF-IDF). La *Term Frequency – Inverse Document Frequency* es una métrica numérica que refleja la relevancia de una palabra en un documento dentro de una colección. Se compone de dos factores:

1. **TF (Term Frequency)**. Mide la frecuencia con la que aparece un término en un documento. A menudo se normaliza para evitar sesgos por la longitud del documento

$$\text{tf}(t, d) = \frac{n_{t,d}}{\sum_k n_{k,d}}$$

donde $n_{t,d}$ es el número de veces que el término t aparece en el documento d .

2. **IDF (Inverse Document Frequency)**. Mide la información que aporta el término. Penaliza los términos que aparecen en muchos documentos (poco discriminantes). Se calcula comúnmente como

$$\text{idf}(t, \mathcal{D}) = \log \left(\frac{|\mathcal{D}|}{|\{d \in \mathcal{D} : t \in d\}| + 1} \right)$$

donde $|\mathcal{D}|$ es el número total de documentos del corpus y el denominador es el número de documentos que contienen el término t más 1, para evitar dividir entre 0 cuando un término no pertenece a ningún documento.

El valor final de TF-IDF para un término t en un documento d se define como:

$$\text{tf-idf}(t, d, \mathcal{D}) = \text{tf}(t, d) \cdot \text{idf}(t, \mathcal{D})$$

Así, un término tendrá un valor alto si aparece frecuentemente en un documento específico (TF alto) pero raramente en el resto de la colección (IDF alto).

Como se observa en la tabla 1.2, al aplicar esta métrica, la matriz término-documento se transforma: cada celda DT_{ij} contendrá el valor TF-IDF correspondiente. El resultado es una representación vectorial ponderada donde cada documento es un vector en $\mathbb{R}^V$, cuyas componentes reflejan la importancia relativa de cada término.

Tabla 1.2.: Matriz Documento-Término ponderada (TF-IDF).

	Documento 1 (d_1)	Documento 2 (d_2)	Documento 3 (d_3)
clustering	0.0000	0.0293	0.0000
de	0.0000	0.0293	0.0000
diez	0.0000	0.0000	0.0000
documentos	0.0000	0.0293	0.0000
el	0.0000	0.0293	0.0000
es	0.0000	0.0293	0.0000
este	0.0000	0.0000	0.0000
interesante	0.0000	0.0293	0.0000
merece	0.0000	0.0000	0.0000
se	0.0293	0.0000	0.0000
tfg	0.0293	0.0000	0.0000
trabajo	0.0000	0.0000	0.0352
un	0.0000	0.0000	0.0000

Cálculo de IDF: Se usa $\log_{10}$. Para términos únicos ($df=1$): $\log(3/2) \approx 0.1761$. Para términos compartidos ($df=2$): $\log(3/3) = 0$.

Observación 1.8. El término «trabajo» tiene un peso mayor que «tfg» (0.0352 vs 0.0293) porque, aunque ambos aparecen una sola vez, el Documento 3 es más corto (5 palabras) que el Documento 1 (6 palabras), aumentando su densidad (TF).

Esta representación, base del modelo de espacio vectorial, ha demostrado ser sólida. Estudios como los de Qaiser y Ali [60], o las revisiones de Bafna et al. [10], corroboran la eficacia de este enfoque en tareas de minería de texto y clustering.

2. Medidas

2.1. Escalares

2.2. Vectoriales

3. Métodos de clustering

Taxonomía [\[59\]](#)

3. Métodos de clustering

3.1. Métodos jerárquicos

3.1.1. Clustering aglomerativo

3.1.2. Clustering divisivo

3.2. Métodos particionales

▷ Creo que meter todos estos métodos bajo clustering particional no tiene realmente mucho sentido. Creo que dependiendo de por donde tiremos ahora (modelos jerárquicos, explorar algún otro tipo de k-means, seguir por métodos específicos de clustering de documentos como LSI / LDA...) podremos elegir una organización u otra

Dentro de los métodos de clustering, encontrar una partición de los datos es uno de los problemas más importantes a resolver [57].

Al contrario que otro tipo de métodos como los jerárquicos, en este caso se elige una partición de los datos que se irá mejorando iterativamente. En muchos casos la elección de las particiones iniciales condicionan el resultado final, y por lo tanto este es un aspecto muy relevante.

3.2.1. Clustering duro

El agrupamiento rígido o *hard clustering* representa el enfoque más tradicional y extendido dentro de los métodos particionales. Su premisa fundamental es la siguiente: dado un conjunto de datos, el algoritmo debe asignar cada observación a un único clúster de forma mutuamente excluyente.

3.2.1.1. K-means

El algoritmo *k-means* fue introducido por [17] en 1967, pero sigue siendo ampliamente usado y mejorado en la actualidad, principalmente por ser extremadamente eficiente y, por lo tanto poder usarlo con grandes cantidades de datos.

Formalmente, tal y como se detalla en [17], dado un conjunto de datos $X = \{\vec{x}_1, \dots, \vec{x}_n\} \subset \mathbb{R}^p$, una partición $S = \{S_1, \dots, S_k\}$ y un conjunto de centroides o representantes $C = \{\vec{c}_1, \dots, \vec{c}_k\}$, buscamos minimizar el criterio de suma de errores cuadráticos (SSE):

$$SSE(S, C) = \sum_{i=1}^k \sum_{\vec{x} \in S_i} \|\vec{x} - \vec{c}_i\|^2$$

El problema de optimización global es NP-duro. El algoritmo estándar (Algoritmo 1) es un método iterativo de minimización alternada que converge a un óptimo local.

Sin embargo, la elección de los centroides no es un problema trivial en absoluto, y ha llevado al desarrollo de variantes de este algoritmo, como el *k-means++* [8], donde se eligen iterativamente teniendo en cuenta la distancia del nuevo centroide con los anteriores.

Es fundamental notar que, para datos finitos, el algoritmo no requiere una tolerancia arbitraria de parada. El procedimiento garantiza la convergencia en un número finito de pasos basándose en dos propiedades: la monotonía de los pasos de asignación y actualización y la finitud del número de posibles particiones de X . Demostremos estas propiedades.

Proposición 3.2. (Monotonía) La sucesión de valores de la función objetivo $\{SSE^{(t)}\}_{t \geq 0}$ es monótona no creciente. Es decir

$$SSE(S^{(t)}, C^{(t)}) \geq SSE(S^{(t+1)}, C^{(t+1)})$$

Algorithm 1 Algoritmo k -means

Require: Conjunto de datos $X = \{\vec{x}_1, \dots, \vec{x}_n\} \subset \mathbb{R}^p$, número de clústers k , número de iteraciones máximas max_iter .

Ensure: Una partición $S = \{S_1, \dots, S_k\}$ y un conjunto de centroides $C = \{\vec{c}_1, \dots, \vec{c}_k\}$ que minimizan localmente el error cuadrático.

1: **Inicialización** ($t = 0$):
 2: Elegir un conjunto inicial arbitrario de centroides $C^{(0)} = \{\vec{c}_1^{(0)}, \dots, \vec{c}_k^{(0)}\}$.
 3: $t \leftarrow 0$
 4: **repeat**
 5: $t \leftarrow t + 1$
 6: **Paso (1): Asignación**
 7: Construir la partición $S^{(t)} = \{S_1^{(t)}, \dots, S_k^{(t)}\}$ inducida por $C^{(t-1)}$, asignando cada punto a su centroide más cercano:
 8:
$$S_i^{(t)} = \left\{ \vec{x} \in X \mid \|\vec{x} - \vec{c}_i^{(t-1)}\|^2 \leq \|\vec{x} - \vec{c}_j^{(t-1)}\|^2, \forall j \neq i \right\}$$

 9: **Paso (2): Actualización**
 10: Recalcular los centroides $C^{(t)} = \{\vec{c}_1^{(t)}, \dots, \vec{c}_k^{(t)}\}$ como la media de los puntos en cada clúster de $S^{(t)}$:
 11:
$$\vec{c}_i^{(t)} = \frac{1}{|S_i^{(t)}|} \sum_{\vec{x} \in S_i^{(t)}} \vec{x}$$

 12: **until** Estacionariedad ($S^{(t)} = S^{(t-1)}$) o $t \geq max_iter$
 13: **return** $S^{(t)}, C^{(t)}$

Observación 3.1. En la implementación clásica y generalizada del algoritmo k -means se usa la distancia euclidiana para calcular la SSE. Esto puede causar problemas a la hora de trabajar con vectores de dimensión muy grande, o al tratar con datos anómalos.

Demostración. Denotemos por $SSE^{(t)} = SSE(S^{(t)}, C^{(t)})$. En la iteración t , primero se calcula $S^{(t)}$ a partir de $C^{(t-1)}$ mediante asignación al centroide más cercano. Para cualquier punto $\vec{x}$, si en la iteración anterior estaba asignado a $\vec{c}_j^{(t-1)}$ y ahora se asigna a $\vec{c}_i^{(t-1)}$, entonces por la regla de asignación se tiene $\|\vec{x} - \vec{c}_i^{(t-1)}\|^2 \leq \|\vec{x} - \vec{c}_j^{(t-1)}\|^2$. Por lo tanto, la contribución de cada punto a la SSE con los centroides viejos no aumenta. Luego,

$$SSE(S^{(t)}, C^{(t-1)}) \leq SSE(S^{(t-1)}, C^{(t-1)}).$$

En el paso de actualización, se calculan los nuevos centroides $C^{(t)}$ como la media de los puntos en cada $S_i^{(t)}$. Dado que la media minimiza la suma de distancias al cuadrado, para cada clúster $S_i^{(t)}$ se cumple

$$\sum_{\vec{x} \in S_i^{(t)}} \|\vec{x} - \vec{c}_i^{(t)}\|^2 \leq \sum_{\vec{x} \in S_i^{(t)}} \|\vec{x} - \vec{c}_i^{(t-1)}\|^2.$$

Sumando sobre todos los clústers, obtenemos

$$SSE(S^{(t)}, C^{(t)}) \leq SSE(S^{(t)}, C^{(t-1)}).$$

Combinando ambas desigualdades, concluimos que

$$SSE(S^{(t-1)}, C^{(t-1)}) \geq SSE(S^{(t)}, C^{(t)}),$$

es decir, la sucesión $\{SSE^{(t)}\}$ es monótona no creciente. $\square$

Proposición 3.3. (*Finititud*) El número de posibles particiones de un conjunto finito es finito.

Demostración. El número de particiones de X en exactamente k subconjuntos no vacíos viene dado por el número de Stirling de segunda especie $S(n, k)$, definido como:

$$S(n, k) = \frac{1}{k!} \sum_{j=0}^k (-1)^{k-j} \binom{k}{j} j^n.$$

Este número es finito para n, k finitos. Además, como cada cluster está identificado por su centroide (y por tanto son distinguibles), el número total de particiones etiquetadas es $k! \cdot S(n, k)$. $\square$

Por tanto, la secuencia de particiones alcanza necesariamente un estado estacionario donde $S^{(t)} = S^{(t-1)}$, ya que en caso contrario el algoritmo mejoraría infinitamente.

Además del algoritmo k -means, existen otros métodos de clustering particional duro que se utilizan en función de las características de los datos. Por ejemplo, el algoritmo k -medoids [37] es una variante que, en lugar de utilizar la media de los puntos como centroide, selecciona un objeto real del conjunto de datos (medoide) como representante de cada clúster. Esto lo hace más robusto frente a ruido y valores atípicos. Otra variante importante es el *spherical k-means* [26], diseñado específicamente para datos en espacios de alta dimensión, como los vectores de texto, donde la similitud coseno es una medida más apropiada que la distancia euclidiana. En este algoritmo, los centroides se normalizan para que tengan norma unitaria, y se maximiza la similitud coseno media dentro de cada clúster. Estos métodos, al igual que k -means, son iterativos y convergen a un óptimo local, pero están adaptados a diferentes necesidades y estructuras de datos.

▷ Creo que deberíamos de incluir el spherical k-means ya que está pensado para trabajar con vectores muy grandes, como los que suelen representar textos

3.2.2. Clustering Difuso

La teoría de conjuntos difusos fue introducida por [81] como una solución al problema de la representación del mundo real mediante la teoría clásica de conjuntos. Veamos el siguiente ejemplo ilustrativo de este problema.

Ejemplo 3.4. Sea $\mathbb{R}$ el conjunto de los números reales. Definimos un subconjunto suyo como

$$A = \{x \in \mathbb{R} \mid x \text{ es mucho más grande que } 1\}$$

Claramente $2 \notin A$, pero no es tan evidente con números más grande como 100, 1000 ...

Este ejemplo muestra que la teoría de conjuntos clásica no puede abordar algunos problemas de la vida real. Por esto, [81] propone una nueva de teoría de conjuntos: *la teoría de conjuntos difusos*

A continuación veremos algunas definiciones y ejemplos básicos de la teoría de conjuntos difusos que nos ayudarán a entender los métodos de clustering difuso.

3. Métodos de clustering

Definición 3.5. (Subconjunto difuso) Sea Ω un conjunto universo, un subconjunto difuso suyo A está caracterizado según su función de pertenencia

$$\mu_A : \Omega \rightarrow [0, 1].$$

De esta manera, cada elemento $x \in \Omega$ tiene asociado un **grado de pertenencia** $\mu_A(x) \in [0, 1]$, donde un valor más cercano a la unidad sugiere mayor grado de pertenencia, y un valor más cercano al 0 menor grado de pertenencia.

En la Figura 3.2 se muestran tres ejemplos comunes de funciones de pertenencia.




Figura 3.1.: Tres ejemplos de funciones de pertenencia para $X = [0, 10]$

Observación 3.6. Es interesante observar que caracterizar un conjunto difuso con una función de pertenencia implica que un conjunto difuso está fuertemente con un conjunto clásico: el dominio de la función pertenencia.

Una vez definido el bloque básico de la teoría de conjuntos difusos, podemos definir sus operaciones básicas.

Para poder trabajar más fácilmente con conjuntos difusos, a continuación defino el dominio y el soporte de un conjunto difuso.

Definición 3.7. (Dominio de un conjunto difuso) Sea A un conjunto difuso, definimos su dominio como el dominio de su función de pertenencia asociada

$$D(A) = D(\mu_A).$$

Definición 3.8. (Soporte de un conjunto difuso) Sea A un conjunto difuso, definimos su soporte como el subconjunto de elementos cuyo grado de pertenencia es positivo.

$$S(A) = \{x \in D(A) \mid \mu_A(x) > 0\}.$$

Con esta nueva definición podemos enfrentarnos fácilmente a las siguientes que resultaran más interesantes.

Definición 3.9. (Unión difusa) Definimos la unión de dos conjuntos difusos como el conjunto difuso caracterizado por la función máximo entre sus funciones de pertenencia

$$A \cup B = C \iff \mu_C(x) = \max(\mu_A(x), \mu_B(x)) \quad \forall x \in D(C) = D(A) \cup D(B)$$

Definición 3.10. (Intersección difusa) Sean A y B dos conjuntos difusos, definimos su intersección C como el caracterizado por la función mínimo entre sus funciones pertenencia.

$$A \cap B = C \iff \mu_C = \min(\mu_A(x), \mu_B(x)) \quad \forall x \in D(C) = S(A) \cap S(B)$$




Figura 3.2.: Representación gráfica de la unión e intersección de conjuntos difusos

Para finalizar esta pequeña introducción de conjuntos difusos, es necesario definir qué es una partición difusa, ya que es un concepto imprescindible en el clustering difuso.

Definición 3.11. (Partición difusa) Sea A un conjunto, se dice que una familia $F = A_1, A_2, \dots, A_n$ de n conjuntos difusos definidos sobre A , con $1 < n < \infty$, constituye una partición difusa de A si y solo si satisface las siguientes dos condiciones:

$$(C1) \quad \forall x \in A, \quad \sum_{i=1}^n \mu_{A_i}(x) = 1$$

$$(C2) \quad \forall i \in \{1, \dots, n\}, \quad \exists x \in A : \mu_{A_i}(x) > 0$$

Esta definición es bastante intuitiva, sobre todo viéndolo desde las perspectiva del clustering difuso, que es nuestra finalidad.

Si consideramos una partición difusa $\{A_i\}$ de un conjunto clásico A , entonces para cada x en A , este pertenece con cierta probabilidad a ciertos conjuntos de la partición. Además, la suma de las probabilidades de pertenencia a estos conjuntos es 1, es decir, x pertenece con probabilidad 1 al conjunto clásico.

Por otro lado, la condición (C2) no es una condición tradicional de la teoría de conjuntos difusos, pero se suele añadir en el estudio de clusterings difusos para asegurarnos que una partición no contiene conjuntos vacíos, es decir, con función de pertenencia constantemente 0.

A partir de la definición de partición difusa, podemos definir la matriz de partición.

Definición 3.12. (Matriz de partición) $U = [\mu_j(x_i)] = [\mu_{ji}] \subset M_{k \times N}$ es la matriz de partición donde $\mu_j(x_i)$ son los grados de pertenencia de los elementos $x_i \in \Omega$, $i \in \{1, 2, \dots, N\}$ en los k subconjuntos difusos $A_j \subset \Omega$, $j \in \{1, 2, \dots, k\}$, los cuales constituyen una partición difusa de Ω .

Observación 3.13. Aunque no se haya hecho explícito en su definición, es importante remarcar que la suma de los elementos de cada fila de una matriz de partición ha de ser 1. Esto se debe a la condición (C1), que obliga a que la suma de los grados de pertenencia de un elemento x_i a cada subconjunto difuso de la partición sumen 1. Al representar cada fila los diferentes grados de pertenencia de un elemento a los subconjuntos de la partición, la condición nos asegura que la suma de los elementos de una fila ha de ser 1.

3.2.2.1. Fuzzy k -means

Así como la teoría de conjuntos difusos surge como una generalización de la teoría de conjuntos clásicos para poder reflejar mejor la realidad, el algoritmo Fuzzy k -means (También conocido como FCM [16]) es una generalización del k -means clásico que genera clústers difusos.

Un problema muy extendido en el análisis de datos en general es la presencia de valores anómalos. En el siguiente ejemplo se puede ver cómo algoritmos de clustering difuso como el FCM es capaz de resolver parte de este problema para el clustering, ya que dota al punto anómalo de igual pertenencia a ambos clústers.




Figura 3.3.: Ejemplo de clustering donde un valor anómalo tiene como grado de pertenencia a ambos clústers 0.5

El FCM es una generalización del método k -means porque, al igual que este, busca minimizar el SSE. Sin embargo no se usa directamente este error, sino una función objetivo generalizada basada en él.

Definición 3.14. (Funcional de los mínimos cuadrados generalizado) Sean:

1. $X = \{\vec{x}_1, \vec{x}_2, \dots, \vec{x}_N\}$ un conjunto de elementos
2. $U = (\mu_{ji})$ una matriz de partición de Ω
3. $C = \{\vec{c}_1, \vec{c}_2, \dots, \vec{c}_k\}$ un conjunto de centroides de Ω
4. $m \in (1, \infty)$ el exponente de ponderación o difusificador

5. $d(\cdot, \cdot)$ una distancia

definimos el funcional de mínimos cuadrados generalizado como

$$J_m(U, C) = \sum_{i=0}^N \sum_{j=1}^k (\mu_{ji})^m d(\vec{x}_i, \vec{c}_j)^2$$

Comentemos brevemente este funcional. La principal diferencia con la función objetivo del algoritmo k -means es el término $(\mu_{ji})^m$, que denota los grados de pertenencia de los elementos $\vec{x}_i$ a los clústers S_j elevados a un valor m llamado difusor. Al ser el k -means un algoritmo de clustering duro, los grados de pertenencia sólo pueden tomar los valores 0, es decir, el elemento no se tiene en cuenta porque no pertenece al cluster; o 1, es decir, el elemento solo pertenece a ese conjunto y no influye en el resto de la expresión.

Sin embargo, al estar en el contexto de la teoría de conjuntos difusos, tiene sentido ponderar el error de cada elemento respecto a su centroide mediante su grado de pertenencia al subconjunto difuso asociado.

Un elemento diferenciador importante es el exponente de ponderación o difusificador. Cuanto más alto sea este valor, más "difusos" serán los clusters que se formen. Esto se ve claramente en la función de actualización de los grados de pertenencia 3.15, donde cuando m tiende a 1 los grados de pertenencia tienden a 1 o 0 (3.16); y cuando m tiende a ∞ los grados de pertenencia tienden a $\frac{1}{k}$.

A partir de la definición de este funcional 3.14 encontraremos la forma de actualizar los centroides y la matriz de partición iterativamente, con el fin de conseguir nuestros objetivos.

Proposición 3.15. El mínimo de J_m ($m \neq 1$) respecto a μ_{ri} se alcanza en

$$\mu_{ri} = \frac{1}{\sum_{j=1}^k \left(\frac{d(\vec{x}_i, \vec{c}_r)}{d(\vec{x}_i, \vec{c}_j)} \right)^{\frac{2}{m-1}}}.$$

Demostración. Este problema está sujeto a la restricción de que la suma de las pertenencias de un elemento del universo $\vec{x}_i \in \Omega$ a todos los clústeres debe ser 1:

$$\sum_{j=1}^k \mu_{ji} = 1, \quad \forall i \in \{1, \dots, N\}$$

Este es un problema de optimización con restricciones, y por lo tanto podemos usar el método de los multiplicadores de Lagrange. Para ello, construiremos el Lagrangiano:

$$L(\mu_{1i}, \dots, \mu_{ki}, \lambda_i) = \sum_{j=1}^k (\mu_{ji})^m d(\vec{x}_i, \vec{c}_j)^2 - \lambda_i \left(\sum_{j=1}^k \mu_{ji} - 1 \right)$$

donde λ_i es el multiplicador de Lagrange asociado a la restricción para $\vec{x}_i$.

Calculamos la derivada parcial con respecto a una pertenencia específica μ_{ki} y la igualamos a cero:

$$\frac{\partial L}{\partial \mu_{ri}} = m(\mu_{ri})^{m-1} d(\vec{x}_i, \vec{c}_r)^2 - \lambda_i = 0.$$

3. Métodos de clustering

Despejamos μ_{ri} :

$$\begin{aligned} m(\mu_{ri})^{m-1}d(\vec{x}_i, \vec{c}_r)^2 &= \lambda_i \\ (\mu_{ri})^{m-1} &= \frac{\lambda_i}{md(\vec{x}_i, \vec{c}_r)^2} \\ \mu_{ri} &= \left(\frac{\lambda_i}{m}\right)^{\frac{1}{m-1}} \left(\frac{1}{d(\vec{x}_i, \vec{c}_r)^2}\right)^{\frac{1}{m-1}} \end{aligned}$$

Ahora, utilizamos la restricción original para encontrar el valor de λ_i . Sustituimos esta expresión para μ_{ji} en la ecuación de la restricción $\sum_{j=1}^k \mu_{ji} = 1$:

$$\sum_{j=1}^k \left[\left(\frac{\lambda_i}{m}\right)^{\frac{1}{m-1}} \left(\frac{1}{d(\vec{x}_i, \vec{c}_j)^2}\right)^{\frac{1}{m-1}} \right] = 1$$

El término con λ_i es constante respecto al índice j , por lo que puede salir de la suma:

$$\left(\frac{\lambda_i}{m}\right)^{\frac{1}{m-1}} \sum_{j=1}^k \left(\frac{1}{d(\vec{x}_i, \vec{c}_j)^2}\right)^{\frac{1}{m-1}} = 1$$

Despejamos el término con λ_i :

$$\left(\frac{\lambda_i}{m}\right)^{\frac{1}{m-1}} = \frac{1}{\sum_{j=1}^k \left(\frac{1}{d(\vec{x}_i, \vec{c}_j)^2}\right)^{\frac{1}{m-1}}}$$

Finalmente, sustituimos esta expresión de vuelta en la ecuación para μ_{ri} :

$$\mu_{ri} = \frac{\left(\frac{1}{d(\vec{x}_i, \vec{c}_r)^2}\right)^{\frac{1}{m-1}}}{\sum_{j=1}^r \left(\frac{1}{d(\vec{x}_i, \vec{c}_j)^2}\right)^{\frac{1}{m-1}}} = \frac{1}{\sum_{j=1}^r \left(\frac{d(\vec{x}_i, \vec{c}_r)}{d(\vec{x}_i, \vec{c}_j)}\right)^{\frac{2}{m-1}}}$$

□

Nótese que la ecuación 3.15 define de manera unívoca cómo debe repartirse la pertenencia de un punto entre los diferentes clústers en función de sus distancias relativas, siendo este el paso crítico que diferencia al clustering difuso del particionado rígido.

Observación 3.16. ¿Qué pasa cuando $m = 1$? Esta es una pregunta muy pertinente, y su respuesta ilustrativa. Si tomamos el límite cuando m tiende a 1, tenemos $\lim_{m \rightarrow 1} \frac{2}{m-1} = \infty$. Estudiemos el cociente de las distancias. Si suponemos que solo existe un centroide más cercano c_a para x_i , entonces $d(x_i, c_a) < d(x_i, c_j) \quad \forall a \neq j$. Para el caso μ_{ai} , tenemos que la suma tendrá la forma $1^{\frac{2}{m-1}} + \sum_{j \neq a}^k \left(\frac{d(x_i, c_r)}{d(x_i, c_j)}\right)^{\frac{2}{m-1}}$. Teniendo en cuenta la desigualdad anterior, nos queda que el límite de la suma es 1, y por lo tanto $\mu_{ia} = 1$. Para el resto de los grados de pertenencia μ_{ri} tal que $r \neq a$, sabemos que en su suma se encuentra el cociente $\frac{d(x_i, c_r)}{d(x_i, c_a)} > 1$, y por lo tanto el límite tiende a infinito, y el grado de pertenencia tiende a

0. Recapitulando, cuando m tiende a 1, al usar esta expresión para actualizar la matriz de partición, nos aproximaremos a la versión dura del FCM, el k -means.

La relevancia de la Proposición 3.15 es fundamental para el algoritmo: constituye el núcleo analítico del FCM. Hemos transformado un problema de optimización teórica bajo restricciones en una regla de actualización explícita. Esta expresión garantiza que, conocidos los centroides en una iteración dada, la actualización de la matriz de partición es la que minimiza de forma óptima el funcional J_m . Es, por tanto, el motor que permite el descenso iterativo hacia un mínimo local del error.

También necesitamos una expresión para actualizar los centroides, pero en este caso no es tan fácil, ya que necesitamos saber la expresión de la distancia para poder despejarlos adecuadamente.

Por lo tanto, a partir de este momento usaremos la distancia euclidiana, y tomaremos como universo $\Omega = \mathbb{R}^V$.

Proposición 3.17. *El mínimo de J_m ($m \neq 1$) respecto a $\vec{c}_j$ se alcanza en*

$$\vec{c}_r = \frac{\sum_{i=1}^N (u_{ri}^m) \vec{x}_i}{\sum_{i=1}^N (u_{ri}^m)}.$$

Demostración. Tenemos la expresión del funcional, con $d(\vec{x}_i, \vec{c}_r) = \|\vec{x}_i - \vec{c}_r\| = \sqrt{\sum_{l=1}^V (\vec{x}_i(l) - \vec{c}_r(l))^2}$ la distancia euclidiana.

$$J_m(U, C) = \sum_{i=1}^N \sum_{j=1}^k (\mu_{ji})^m \|\vec{x}_i - \vec{c}_j\|^2$$

Calculamos su derivada parcial respecto a $\vec{c}_k$

$$\frac{\partial J_m}{\partial \vec{c}_r} = \frac{\partial}{\partial \vec{c}_r} \sum_{i=1}^N \sum_{j=1}^k (\mu_{ji})^m \|\vec{x}_i - \vec{c}_j\|^2$$

La derivada solo afecta al término r -ésimo del sumatorio interno, así que el resto se cancelan

$$\frac{\partial J_m}{\partial \vec{c}_r} = \sum_{i=1}^N (\mu_{ri})^m \frac{\partial}{\partial \vec{c}_r} (\|\vec{x}_i - \vec{c}_r\|^2)$$

Donde

$$\frac{\partial}{\partial \vec{c}_r(l)} \|\vec{x}_i - \vec{c}_r\|^2 = \frac{\partial}{\partial \vec{c}_r(l)} \sum_{l=1}^V (\vec{x}_i(l) - \vec{c}_r(l))^2 = -2(\vec{x}_i(l) - \vec{c}_r(l)) \quad \forall l \in \{0, 1, \dots, V\}$$

Tras sustituir la derivada parcial nos queda la expresión

$$\frac{\partial J_m}{\partial \vec{c}_r} = -2 \sum_{i=1}^N (\mu_{ri})^m (\vec{x}_i - \vec{c}_r)$$

3. Métodos de clustering

Ahora igualamos a 0 para encontrar el mínimo

$$\begin{aligned} -2 \sum_{i=1}^N (\mu_{ri})^m (\vec{x}_i - \vec{c}_r) &= 0 \\ \sum_{i=1}^N (\mu_{ri})^m (\vec{x}_i - \vec{c}_r) &= 0 \\ \sum_{i=1}^N (\mu_{ri})^m \vec{x}_i - \sum_{i=1}^N (\mu_{ri}) \vec{c}_r &= 0 \\ \sum_{i=1}^N (\mu_{ri})^m \vec{x}_i &= \vec{c}_r \sum_{i=1}^N (\mu_{ri}) \end{aligned}$$

Finalmente, despejando $\vec{c}_r$, obtenemos la fórmula

$$\vec{c}_r = \frac{\sum_{i=1}^N (\mu_{ri})^m \vec{x}_i}{\sum_{i=1}^N (\mu_{ri})^m}$$

□

Observación 3.18. Podemos interpretar que el centroide de un clúster es el promedio ponderado de todos los puntos de datos del conjunto, donde la ponderación para cada punto es su grado de pertenencia al clúster elevado al exponente de ponderación.

Una vez derivadas las condiciones de optimalidad para U (matriz de pertenencia) y C (centroides), el algoritmo FCM se estructura como un proceso de optimización alternada. En cada paso, se fija una variable para optimizar la otra, asegurando así la convergencia hacia un mínimo local del funcional J_m .

Como vemos, la estructura del algoritmo es muy similar a la del clásico k -means. Puede sorprender la ausencia del SSE en el criterio de parada, pero debemos recordar que las fórmulas de actualización de grados de pertenencia y centroides se han conseguido a partir de minimizar localmente el funcional de los mínimos cuadrados generalizado.

En cuanto a la condición de parada, he decidido seguir la definición clásica donde se para al medir una diferencia suficientemente pequeña según una norma matricial arbitraria. Además también se define un número máximo de iteraciones como en el caso del k -means clásico, con el fin de asegurar tiempos de ejecución razonables. Aunque la norma matricial utilizada no suele indicarse en las definiciones de los algoritmos, se pueden usar las normas máximo, mínimo o de Frobenius, entre otras.

3.3. Topic modeling

▷ Escisión temporal

3.3.1. Non-negative matrix factorization

La factorización no negativa de matrices (NMF, por sus siglas en inglés) es una técnica de factorización de matrices que se ha consolidado como un método de referencia para la

Algorithm 2 Algoritmo FCM (Fuzzy C-Means)

Require: Conjunto de datos $X = \{\vec{x}_1, \dots, \vec{x}_N\} \subset \mathbb{R}^V$, número de clústers k , exponente de ponderación $m > 1$, tolerancia ϵ , número máximo de iteraciones max_iter .

Ensure: Una matriz de partición difusa $U = [u_{ji}]$ y un conjunto de centroides $C = \{\vec{c}_1, \dots, \vec{c}_k\}$.

1: **Inicialización** ($t = 0$):

2: Inicializar la matriz de partición $U^{(0)} \in M_{k \times N}$ aleatoriamente, cumpliendo las condiciones de partición ($\sum_{j=1}^k u_{ji} = 1, \forall i$).

3: $t \leftarrow 0$

4: **repeat**

5: $t \leftarrow t + 1$

6: **Paso (1): Actualización de Centroides**

7: Calcular los nuevos centroides $C^{(t)} = \{\vec{c}_1^{(t)}, \dots, \vec{c}_k^{(t)}\}$ utilizando la matriz de partición anterior $U^{(t-1)}$ con la función de actualización de centroides 3.17:

8:

$$\vec{c}_j^{(t)} = \frac{\sum_{i=1}^N (u_{ji}^{(t-1)})^m \vec{x}_i}{\sum_{i=1}^N (u_{ji}^{(t-1)})^m}, \quad \forall j = 1, \dots, k$$

9: **Paso (2): Actualización de Pertenencia**

10: Actualizar la matriz de partición $U^{(t)}$ calculando los nuevos grados de pertenencia basados en las distancias a los centroides $C^{(t)}$ con la función de actualización de grados de pertenencia 3.15:

11:

$$\mu_{ri}^{(t)} = \frac{1}{\sum_{j=1}^k \left(\frac{\|\vec{x}_i - \vec{c}_r^{(t)}\|}{\|\vec{x}_i - \vec{c}_j^{(t)}\|} \right)^{\frac{2}{m-1}}}$$

12: **until** Convergencia ($\|U^{(t)} - U^{(t-1)}\| < \epsilon$) o $t \geq max_iter$

13: **return** $U^{(t)}, C^{(t)}$

extracción de características y el análisis de datos no negativos. En el ámbito del análisis de textos, la NMF es particularmente efectiva para el modelado de tópicos (topic modeling) y el clustering de documentos, debido a su capacidad para generar una representación de los datos basada en partes, lo cual es inherentemente interpretable.

3.3.1.1. Fundamentos teóricos

Sea un corpus de N documentos y un vocabulario de V términos. Este corpus puede ser representado como una matriz término-documento $X \in \mathbb{R}^{V \times N}$, donde cada elemento X_{ij} denota la frecuencia o ponderación (e.g., TF-IDF) del término i en el documento j . Por su naturaleza, esta matriz es no negativa, es decir, $X_{ij} \geq 0 \quad \forall i, j$.

El problema de la NMF es encontrar una aproximación de bajo rango para la matriz X mediante el producto de dos matrices no negativas, W y H .

Definición 3.19. (Problema NMF) Sea $X \in \mathbb{R}^{V \times N}$ no negativa, encontrar $W \in \mathbb{R}^{V \times p}$ y $H \in \mathbb{R}^{p \times N}$ no negativas de bajo rango tal que

$$X = WH + E$$

donde $E \in R^{V \times N}$ es la matriz de error de la aproximación $X \approx WH$.

Observación 3.20. El entero positivo p se conoce como rango de la factorización, y se elige de tal manera que $p \ll \min(V, N)$. p tiene una importancia conceptual clave, ya que representa el número de tópicos latentes que se postula que existen en el corpus.

Al enmarcar la NMF dentro de un paradigma estadístico, es fundamental distinguirla de modelos como el Análisis Factorial (FA). Los modelos estadísticos que subyacen a ambos enfoques son notablemente diferentes. En el FA, se asume que cada fila de la matriz observada es una muestra extraída de una distribución multivariante, la cual permanece constante para todas las filas. Implícitamente, esto supone que los errores de medición tienen una magnitud similar en todo el conjunto de datos.

Por el contrario, el modelo de la NMF (originalmente presentada como Positive Matrix Factorization o PMF [53]) no presupone un proceso de muestreo para los datos. El modelo se considera fundamentalmente determinista: existe una matriz «correcta» y desconocida, producto de los factores WH , que no puede ser observada directamente. Lo que observamos es la matriz X , que es la suma de la matriz correcta WH y una matriz de errores de medición aleatorios E

$$X = WH + E.$$

Desde esta perspectiva, cada elemento observado X_{ij} se descompone en su valor verdadero $[WH]_{ij}$ y un término de error E_{ij} . Antes de realizar la factorización, se debe estimar la magnitud de estos errores, es decir, la desviación estándar de cada elemento de la matriz E . Por lo tanto, el problema de la NMF se reinterpreta como la búsqueda de los parámetros W y H que mejor se ajusten a los datos X , una vez que se ha tenido en cuenta la estructura de los errores. La elección de la función de coste para minimizar la diferencia entre X y WH depende de la supuesta distribución de estos errores: minimizar la distancia euclidiana es equivalente a asumir un ruido Gaussiano, mientras que minimizar la divergencia de Kullback-Leibler corresponde a un ruido con distribución de Poisson.

Esta visión es fundamental en el análisis de textos, donde la NMF se aplica extensamente para el modelado de tópicos (topic modeling). En este contexto, la descomposición adquiere una interpretación semántica potente. La matriz X se concibe como una mezcla de varios temas o «tópicos» latentes que subyacen en el corpus, y la NMF tiene la capacidad de descubrir estos tópicos y cuantificar su presencia en cada documento.

En el campo del clustering de texto, las matrices W y H adquieren significados intrínsecos. W es la matriz de tópicos, donde cada una de sus columnas representa un tópico latente, y sus elementos W_{ik} ponderan la importancia del término i en el tema k . Análogamente, la matriz H es la matriz de activaciones, donde cada una de sus columnas relaciona un documento con los tópicos que lo componen. Cada elemento H_{kj} indica el grado de pertenencia del documento j al tema k . Gracias a que ambas matrices son no negativas, los documentos pueden describirse como combinaciones lineales aditivas de los tópicos base, lo que facilita una interpretación directa y clara de los resultados.

3.3.1.2. Objetivos de Coste

La resolución del problema de NMF está estrechamente ligada con la elección de una función de coste que mida la divergencia o el error entre la matriz original X y su aproximación WH , y por lo tanto cada función de coste define un nuevo problema NMF.




Figura 3.4.: Representación de la interpretación semántica del NMF para el clustering textual

En [43] se describen dos funciones de coste generalmente usadas, así como sus algoritmos asociados: La Distancia Euclidiana y la Divergencia de KL. Ambas funciones se pueden deducir calculando la función de verosimilitud de $X - WH = E$, considerando la Matriz U como ruido gaussiano o de Poisson, respectivamente.

Definición 3.21. (Distancia euclidiana) Sean $A = a_{ij}$, $B = b_{ij} \in M^{n \times m}$, definimos la distancia euclidiana entre A y B como

$$\|A - B\|_F^2 = \sum_{i=0}^n \sum_{j=0}^m (a_{ij} - b_{ij})^2$$

donde $\|\cdot\|_F$ representa la Norma de Frobenious.

Proposición 3.22. Minimizar la distancia euclidiana al cuadrado $\|X - WH\|_F^2$ es equivalente a maximizar la log-verosimilitud del modelo generativo $X = WH + E$, bajo el supuesto de que el ruido E sigue una distribución Gaussiana con media cero.

Asumimos un modelo generativo donde cada elemento de la matriz de datos observada X se genera a partir de la aproximación WH con un ruido aditivo Gaussiano. Es decir, para cada elemento:

$$X_{ij} = [WH]_{ij} + E_{ij}, \quad \text{donde } E_{ij} \sim \mathcal{N}(0, \sigma^2).$$

Esto implica que cada X_{ij} es una variable aleatoria que sigue una distribución Gaussiana con media $[WH]_{ij}$ y varianza σ^2 :

$$X_{ij} \sim \mathcal{N}([WH]_{ij}, \sigma^2).$$

La función de densidad de probabilidad para un solo elemento X_{ij} es:

$$P(X_{ij}|W, H, \sigma) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(X_{ij} - [WH]_{ij})^2}{2\sigma^2}\right).$$

Asumiendo que los errores de medición son estadísticamente independientes entre sí, la función de verosimilitud de la matriz completa X es el producto de las densidades de cada uno de sus elementos:

3. Métodos de clustering

$$L(W, H|X) = P(X|W, H) = \prod_{i=1}^V \prod_{j=1}^N \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(X_{ij} - [WH]_{ij})^2}{2\sigma^2}\right).$$

Para simplificar la optimización, trabajamos con la log-verosimilitud ($\log L$):

$$\begin{aligned} \log L(W, H|X) &= \sum_{i=1}^V \sum_{j=1}^N \log \left[\frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(X_{ij} - [WH]_{ij})^2}{2\sigma^2}\right) \right] \\ \log L(W, H|X) &= \sum_{i=1}^V \sum_{j=1}^N \left[\log\left(\frac{1}{\sqrt{2\pi\sigma^2}}\right) - \frac{(X_{ij} - [WH]_{ij})^2}{2\sigma^2} \right] \\ \log L(W, H|X) &= -\frac{VN}{2} \log(2\pi\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^V \sum_{j=1}^N (X_{ij} - [WH]_{ij})^2 \end{aligned}$$

Nuestro objetivo es encontrar los W y H que maximizan esta expresión. El primer término, $-\frac{VN}{2} \log(2\pi\sigma^2)$, es una constante con respecto a W y H . Por lo tanto, maximizar la log-verosimilitud es equivalente a minimizar el segundo término:

$$\min_{W, H \geq 0} \sum_{i=1}^V \sum_{j=1}^N (X_{ij} - [WH]_{ij})^2.$$

Esta suma no es más que el cuadrado de la norma de Frobenius de la matriz diferencia $X - WH$

$$\sum_{i=1}^V \sum_{j=1}^N (X_{ij} - [WH]_{ij})^2 = \|X - WH\|_F^2.$$

Así, hemos demostrado que el problema de NMF con la distancia euclidiana como función de coste se deriva directamente del principio de máxima verosimilitud bajo un supuesto de ruido Gaussiano.

Minimizar el cuadrado de la norma de Frobenius, $\|X - WH\|_F^2$, tiene una interpretación geométrica muy intuitiva: busca la aproximación WH cuyos vectores columna estén, en promedio, lo más cerca posible de los vectores columna originales de X en el espacio euclidiano. Como se ha demostrado, esta perspectiva se alinea perfectamente con un modelo estadístico en el que los datos observados X son una versión de la matriz «real» WH a la que se le ha añadido un ruido con distribución Gaussiana.

Definición 3.23. (Divergencia KL)

$$D(X||WH) = \sum_{i,j} (X_{ij} \log\left(\frac{X_{ij}}{[WH]_{ij}}\right) - X_{ij} + [WH]_{ij}).$$

Proposición 3.24. Minimizar la divergencia de Kullback-Leibler $D_{KL}(X||W, H)$ es equivalente a maximizar la log-verosimilitud del modelo generativo $X = WH + E$, bajo el supuesto de que el ruido U sigue una distribución de Poisson.

Asumimos un modelo generativo en el que cada elemento observado X_{ij} de la matriz de datos es una variable aleatoria extraída de una distribución de Poisson. El parámetro de tasa λ_{ij} (el valor esperado) de esta distribución está dado por el elemento correspondiente en la matriz de aproximación, $[WH]_{ij}$,

$$X_{ij} \sim \text{Poisson}(\lambda_{ij} = [WH]_{ij}).$$

La función de masa de probabilidad (PMF) de la distribución de Poisson para un solo evento observado X_{ij} (que es un recuento entero y no negativo) es:

$$P(X_{ij}|W, H) = \frac{(\lambda_{ij})^{X_{ij}} e^{-\lambda_{ij}}}{X_{ij}!} = \frac{([WH]_{ij})^{X_{ij}} e^{-[WH]_{ij}}}{X_{ij}!}.$$

Suponiendo que todos los elementos de la matriz son estadísticamente independientes, la función de verosimilitud conjunta para la matriz completa X es el producto de las probabilidades individuales:

$$L(W, H|X) = P(X|W, H) = \prod_{i=1}^V \prod_{j=1}^N \frac{([WH]_{ij})^{X_{ij}} e^{-[WH]_{ij}}}{X_{ij}!}.$$

Para facilitar la optimización, trabajamos con la log-verosimilitud, aplicando el logaritmo a la expresión anterior:

$$\begin{aligned} \log L(W, H|X) &= \sum_{i=1}^V \sum_{j=1}^N \log \left(\frac{([WH]_{ij})^{X_{ij}} e^{-[WH]_{ij}}}{X_{ij}!} \right) \\ \log L(W, H|X) &= \sum_{i=1}^V \sum_{j=1}^N [X_{ij} \log([WH]_{ij}) - [WH]_{ij} - \log(X_{ij}!)] \end{aligned}$$

El objetivo es encontrar los parámetros W y H que maximizan esta log-verosimilitud. El término $\sum \log(X_{ij}!)$ depende únicamente de los datos observados X , por lo que es una constante con respecto a los parámetros W y H que queremos optimizar. Por lo tanto, podemos ignorarlo durante la optimización. Maximizar la log-verosimilitud es equivalente a maximizar:

$$\max_{W, H \geq 0} \sum_{i=1}^V \sum_{j=1}^N [X_{ij} \log([WH]_{ij}) - [WH]_{ij}].$$

Ahora, examinemos la definición de la divergencia de Kullback-Leibler, $D_{KL}(X||WH)$:

$$\begin{aligned} D_{KL}(X||WH) &= \sum_{i=1}^V \sum_{j=1}^N \left(X_{ij} \log \left(\frac{X_{ij}}{[WH]_{ij}} \right) - X_{ij} + [WH]_{ij} \right) \\ D_{KL}(X||WH) &= \sum_{i=1}^V \sum_{j=1}^N [X_{ij} \log(X_{ij}) - X_{ij} \log([WH]_{ij}) - X_{ij} + [WH]_{ij}] \end{aligned}$$

Para minimizar esta expresión, podemos, de nuevo, ignorar los términos que no dependen de W y H , que en este caso son $\sum_{ij} (X_{ij} \log(X_{ij}) - X_{ij})$. Por tanto, minimizar la divergencia KL es equivalente a minimizar:

$$\min_{W, H \geq 0} \sum_{i=1}^V \sum_{j=1}^N [-X_{ij} \log([WH]_{ij}) + [WH]_{ij}].$$

Observamos que la expresión a minimizar es exactamente el negativo de la expresión que que-

3. Métodos de clustering

ríamos maximizar en el problema de máxima verosimilitud. Es decir, $\max_{W,H \geq 0} L(W,H|X) = \min_{W,H \geq 0} -D_{KL}(X||WH)$.

Por lo tanto, hemos demostrado que minimizar la divergencia KL es matemáticamente equivalente a encontrar los estimadores de máxima verosimilitud para los parámetros W y H bajo un modelo de ruido de Poisson. Esto establece la divergencia KL como la función de coste natural y teóricamente fundamentada para la NMF aplicada a datos de recuento.

La divergencia KL, originaria de la teoría de la información, se ha consolidado como la alternativa principal a la distancia euclidiana, especialmente en dominios donde los datos representan recuentos o frecuencias. Su derivación a partir de un modelo de ruido de Poisson es la razón fundamental de su éxito en áreas como el procesamiento de texto.

La distribución de Poisson modela la probabilidad de que ocurra un número de eventos en un intervalo fijo, asumiendo que estos eventos ocurren con una tasa media conocida e independientemente del tiempo transcurrido desde el último evento. Esto la convierte en el modelo estadístico ideal para datos de conteo, como el número de veces que una palabra aparece en un documento.

Es fundamental señalar que, si bien estas derivaciones estadísticas proporcionan una justificación teórica elegante, sus supuestos subyacentes no siempre se cumplen rigurosamente en la práctica. Por ejemplo, el supuesto de que todos los elementos X_{ij} son estadísticamente independientes es poco realista en una matriz de término-documento. La aparición de la palabra «algoritmo» en un texto aumenta significativamente la probabilidad de encontrar la palabra «aprendizaje», rompiendo la independencia.

Por lo tanto, en muchas aplicaciones, es más útil concebir estas funciones de coste no como la validación de un modelo generativo estricto, sino como métricas que poseen propiedades deseables para ciertos tipos de datos y objetivos. La distancia euclídea se elige por su simplicidad y su interpretación geométrica cuando se buscan agrupamientos flexibles, mientras que la divergencia KL se prefiere por su robustez y su afinidad natural con los datos de conteo, lo que a menudo conduce a resultados más interpretables en dominios como el análisis de texto. La elección entre una y otra se convierte, en última instancia, en una decisión de modelado que depende de la naturaleza de los datos y del objetivo final del análisis.

3.3.1.3. Algoritmos de Optimización

Para encontrar las matrices W y H que minimizan la distancia euclidiana, se emplean algoritmos iterativos. Los más comunes son las reglas de actualización multiplicativa propuestas por Lee y Seung. Estas reglas actualizan alternativamente W y H de una manera que garantiza que la función de coste no aumente en cada paso y que las matrices permanezcan no negativas. Usaremos una demostración basada en la técnica de gradiente descendiente descrita por [7].

Lema 3.25. *Se cumplen las siguientes propiedades sobre la traza y la norma de Frobenius para matrices conformes:*

- (I) $\|X\|_F^2 = \text{tr}(X^T X)$.
- (II) $\text{tr}(AB) = \text{tr}(BA)$, si AB es cuadrada.
- (III) $\nabla_X \text{tr}(AXB) = A^T B^T$, si AXB es cuadrada.
- (IV) $\nabla_X \text{tr}(X^T AX) = (A + A^T)X$.

$$(v) \nabla_X \text{tr}(B^T X^T X B) = 2XBB^T.$$

Demostración. (i) Por definición de la norma de Frobenius y de la traza:

$$\|X\|_F^2 = \sum_{i,j} X_{ij}^2 = \sum_j \left(\sum_i X_{ij}^2 \right) = \sum_j [X^T X]_{jj} = \text{tr}(X^T X).$$

(ii) El elemento $[AB]_{ii}$ es $\sum_j A_{ij}B_{ji}$ y el elemento $(BA)_{jj}$ es $\sum_i B_{ji}A_{ij}$. La traza es la suma de estos elementos sobre i y j respectivamente, resultando en la misma suma doble:

$$\text{tr}(AB) = \sum_i \sum_j A_{ij}B_{ji} = \sum_j \sum_i B_{ji}A_{ij} = \text{tr}(BA).$$

(iii) Usando la propiedad (ii), $\text{tr}(AXB) = \text{tr}(XBA)$. Sea $f(X) = \text{tr}(XC)$ con $C = BA$. Componente a componente, la derivada es:

$$f(X) = \sum_{i,j} X_{ij}C_{ji} \implies \frac{\partial f}{\partial X_{kl}} = C_{lk} = [C^T]_{kl}.$$

Por tanto, $\nabla_X f = C^T = (BA)^T = A^T B^T$.

(iv) Sea $f(X) = \text{tr}(X^T A X)$. Expresando la traza componente a componente:

$$f(X) = \sum_k [X^T A X]_{kk} = \sum_k \sum_i [X^T]_{ki} [A X]_{ik} = \sum_{k,i} X_{ik} \sum_j A_{ij} X_{jk} = \sum_{i,j,k} X_{ik} A_{ij} X_{jk}.$$

Al derivar respecto a un elemento X_{rs} , este aparece en la suma cuando $(i, k) = (r, s)$ y cuando $(j, k) = (r, s)$:

$$\begin{aligned} \frac{\partial f}{\partial X_{rs}} &= \frac{\partial}{\partial X_{rs}} \left(\sum_{i,j,k} X_{ik} A_{ij} X_{jk} \right) \\ &= \sum_j A_{rj} X_{js} + \sum_i X_{is} A_{ir} \\ &= [A X]_{rs} + [A^T X]_{rs} \\ &= [(A + A^T) X]_{rs}. \end{aligned}$$

Así, el gradiente es $\nabla_X f(X) = (A + A^T) X$.

(v) Sea $f(X) = \text{tr}(B^T X^T X B)$. Usando la propiedad (i), vemos que la traza es la norma de Frobenius al cuadrado de XB :

$$f(X) = \|XB\|_F^2 = \sum_{i,k} [XB]_{ik}^2 = \sum_{i,k} \left(\sum_j X_{ij} B_{jk} \right)^2.$$

Derivamos respecto al elemento X_{rs} usando la regla de la cadena:

$$\frac{\partial f}{\partial X_{rs}} = \sum_{i,k} 2 \left(\sum_j X_{ij} B_{jk} \right) \frac{\partial}{\partial X_{rs}} \left(\sum_j X_{ij} B_{jk} \right).$$

3. Métodos de clustering

La derivada interna solo es no nula cuando $i = r$, resultando en B_{sk} . Sustituyendo:

$$\frac{\partial f}{\partial X_{rs}} = \sum_k 2 \left(\sum_j X_{rj} B_{jk} \right) B_{sk} = 2 \sum_k [XB]_{rk} B_{sk} = 2 \sum_k [XB]_{rk} [B^T]_{ks}.$$

La última expresión es el elemento rs de la matriz $2XBB^T$, por lo que $\nabla_X f(X) = 2XBB^T$. $\square$

Una vez hemos demostrado las propiedades anteriores, procedemos a solucionar el problema de minimización para la función objetivo $\|X - WH\|_F^2$.

Para ello usaremos el método de Descenso Gradiente, alternando entre optimizar W y H . Veamos la forma para minimizar una cierta función f según este método:

$$x^{k+1} = x^k - t^k \nabla_x f(x^k).$$

Donde $k \in \mathbb{N}$ es la iteración, x^k es la variable actual, x^{k+1} la variable de la siguiente iteración, $t^k \geq 0$ el tamaño del paso y $\nabla_x f(x)$ el gradiente de la función objetivo f con respecto a x .

Para nuestro problema, podemos definir la función objetivo como $f(W, H) = \frac{1}{2} \|X - WH\|_F^2$, de dos variables, y por lo tanto buscamos una secuencia $\{W^k, H^k\}_{k \in \mathbb{N}}$ tal que la función objetivo decrezca monótonamente, $f(W^{k+1}, H^{k+1}) \leq f(W^k, H^k)$.

Recapitulando, tenemos el siguiente problema:

$$\arg \min_{W \geq 0, H \geq 0} \frac{1}{2} \|X - WH\|_F^2.$$

Y usaremos el método de gradiente descendiente, aplicándolo alternamente a W y a H

$$\begin{aligned} W^{k+1} &= W^k - t_W^k \nabla_W f(W^k, H^k) \\ H^{k+1} &= H^k - t_H^k \nabla_H f(W^{k+1}, H^k) \end{aligned}$$

Debemos de calcular los gradientes de la función, $\nabla_W f$ y $\nabla_H f$, así como los pasos t_W^k y t_H^k .

Empezaremos por los gradientes. Para ello, desarrollaremos la expresión de la función objetivo f usando las propiedades anteriormente demostradas.

$$\begin{aligned} f(W, H) &= \frac{1}{2} \|X - WH\|_F^2 \\ &\stackrel{(I)}{=} \frac{1}{2} \text{tr} \left((X - WH)^T (X - WH) \right) \\ &= \frac{1}{2} \text{tr} \left(X^T X - X^T WH - (WH)^T X + (WH)^T (WH) \right) \\ &= \frac{1}{2} \text{tr} \left(X^T X - 2(WH)^T X + H^T W^T WH \right) \\ &\stackrel{(I)}{=} \frac{1}{2} \|X\|_F^2 - \text{tr} \left((WH)^T X \right) + \frac{1}{2} \text{tr} \left(H^T W^T WH \right) \end{aligned}$$

Con esta expresión calculamos fácilmente los gradientes

$$\begin{aligned}
\nabla_W f &= -\nabla_W \text{tr}(X^T W H) + \frac{1}{2} \nabla_W \text{tr}(H^T W^T W H) \\
&\stackrel{(\text{III}), (\text{V})}{=} -X H^T + W H H^T \\
&= (W H - X) H^T \\
\nabla_H f &= -\nabla_H \text{tr}(X^T W H) + \frac{1}{2} \nabla_H \text{tr}(H^T W^T W H) \\
&\stackrel{(\text{III}), (\text{IV}), (\text{II})}{=} -W^T X + W^T W H \\
&= W^T (W H - X)
\end{aligned}$$

Para la elección de los pasos tenemos más libertad, ya que son parámetros libres. Sin embargo, tenemos que tener en cuenta las restricciones de no negatividad de W y H . Se proponen los siguientes pasos definidos componente a componente

$$[t_W]_{ij} = \frac{[W]_{ij}}{[W H H^T]_{ij}} \quad [t_H]_{ij} = \frac{[H]_{ij}}{[W^T W H]_{ij}}.$$

Estos pasos se eligen estratégicamente para cancelar los términos sustractivos de la actualización aditiva, convirtiéndola en una actualización multiplicativa que garantiza por construcción la no negatividad de los factores. Podemos ver que la actualización da matrices no negativas.

$$\begin{aligned}
[W_{k+1}]_{ij} &= [W_k]_{ij} - [t_W]_{ij} [\nabla_W f]_{ij} \\
&= [W_k]_{ij} - \frac{[W_k]_{ij}}{[W_k H_k H_k^T]_{ij}} [(W_k H_k - X) H_k^T]_{ij} \\
&= [W_k]_{ij} - \frac{[W_k]_{ij}}{[W_k H_k H_k^T]_{ij}} [W_k H_k H_k^T - X H_k^T]_{ij} \\
&= [W_k]_{ij} \left(1 - \frac{[W_k H_k H_k^T - X H_k^T]_{ij}}{[W_k H_k H_k^T]_{ij}} \right) \\
&= [W_k]_{ij} \left(\frac{[W_k H_k H_k^T]_{ij} - [W_k H_k H_k^T - X H_k^T]_{ij}}{[W_k H_k H_k^T]_{ij}} \right) \\
&= [W_k]_{ij} \frac{[X H_k^T]_{ij}}{[W_k H_k H_k^T]_{ij}}
\end{aligned}$$

Como $X \geq 0$, $W_k \geq 0$ y $H_k \geq 0$ por hipótesis inductiva, todos los elementos en el numerador y denominador son no negativos, garantizando que $[W_{k+1}]_{ij} \geq 0$.

De manera análoga para H :

3. Métodos de clustering

$$\begin{aligned}
[H_{k+1}]_{ij} &= [H_k]_{ij} - [t_H]_{ij} [\nabla_H f]_{ij} \\
&= [H_k]_{ij} - \frac{[H_k]_{ij}}{[W_{k+1}^T W_{k+1} H_k]_{ij}} [W_{k+1}^T (W_{k+1} H_k - X)]_{ij} \\
&= [H_k]_{ij} - \frac{[H_k]_{ij}}{[W_{k+1}^T W_{k+1} H_k]_{ij}} [W_{k+1}^T W_{k+1} H_k - W_{k+1}^T X]_{ij} \\
&= [H_k]_{ij} \left(1 - \frac{[W_{k+1}^T W_{k+1} H_k - W_{k+1}^T X]_{ij}}{[W_{k+1}^T W_{k+1} H_k]_{ij}} \right) \\
&= [H_k]_{ij} \left(\frac{[W_{k+1}^T W_{k+1} H_k]_{ij} - [W_{k+1}^T W_{k+1} H_k - W_{k+1}^T X]_{ij}}{[W_{k+1}^T W_{k+1} H_k]_{ij}} \right) \\
&= [H_k]_{ij} \frac{[W_{k+1}^T X]_{ij}}{[W_{k+1}^T W_{k+1} H_k]_{ij}}
\end{aligned}$$

Nuevamente, como todas las matrices involucradas son no negativas, $[H_{k+1}]_{ij} \geq 0$.

Expresando estas actualizaciones en notación matricial compacta, obtenemos las fórmulas de actualización multiplicativa:

$$\begin{aligned}
W_{k+1} &= W_k \circ \frac{X H_k^T}{W_k H_k H_k^T} \\
H_{k+1} &= H_k \circ \frac{W_{k+1}^T X}{W_{k+1}^T W_{k+1} H_k}
\end{aligned}$$

Donde tanto la multiplicación $\circ$ como la división son componente a componente.

De una forma similar, podemos solucionar el problema de minimización para la función objetivo KL

$$f(W, H) = D(X || WH) = \sum_{i,j} \left(X_{ij} \log \left(\frac{X_{ij}}{[WH]_{ij}} \right) - X_{ij} + [WH]_{ij} \right).$$

Primero debemos de calcular los gradientes de la función, $\nabla_W f$ y $\nabla_H f$. Para ello desarrollamos el logaritmo de f facilitando la diferenciación

$$f(W, H) = \sum_{i,j} (X_{ij} \log(X_{ij}) - X_{ij} \log([WH]_{ij}) - X_{ij} + [WH]_{ij}).$$

$$\begin{aligned}
\frac{\partial f}{\partial W_{ik}} &= - \sum_j X_{ij} \frac{1}{[WH]_{ij}} \frac{\partial [WH]_{ij}}{\partial W_{ik}} + \sum_j \frac{\partial [WH]_{ij}}{\partial W_{ik}} \\
&\text{Sabido que } [WH]_{ij} = \sum_l W_{il} H_{lj} \implies \frac{\partial [WH]_{ij}}{\partial W_{ik}} = H_{kj} \\
&= - \sum_j \frac{X_{ij}}{[WH]_{ij}} H_{kj} + \sum_j H_{kj} \\
&= \sum_j H_{kj} \left(1 - \frac{X_{ij}}{[WH]_{ij}} \right) \\
&= \sum_j [\mathbf{1} - X \odot WH]_{ij} [H^T]_{jk} \\
&= [(\mathbf{1} - X \odot WH) H^T]_{ik}
\end{aligned}$$

Por lo tanto, en notación matricial completa:

$$\nabla_W f = (\mathbf{1} - X \odot WH) H^T.$$

De manera similar obtenemos el diferencial $\nabla_H f = W^T(\mathbf{1} - X \odot WH)$, ordenando adecuadamente los productos de matrices para que estén bien definidos.

Para la elección de los pasos tenemos más libertad, ya que son parámetros libres. Sin embargo, tenemos que tener en cuenta las restricciones de no negatividad de W y H . Se proponen los siguientes pasos definidos componente a componente

$$[t_W]_{ij} = \frac{W_{ij}^K}{\sum_l H_{lj}^K} \quad [t_H]_{ij} = \frac{H_{ij}^K}{\sum_l W_{il}^K}.$$

Estos pasos se eligen estratégicamente para cancelar los términos sustractivos de la actualización aditiva, convirtiéndola en una actualización multiplicativa que garantiza por construcción la no negatividad de los factores.

Calculamos la expresión de actualización para W :

$$\begin{aligned}
[W_{k+1}]_{ik} &= [W_k]_{ik} - [t_W]_{ik} [\nabla_W f]_{ik} \\
&= [W_k]_{ik} - \frac{[W_k]_{ik}}{\sum_j [H_k]_{kj}} \left[(\mathbf{1} - X \odot W_k H_k) H_k^T \right]_{ik} \\
&= [W_k]_{ik} \left(1 - \frac{\sum_j (1 - [X]_{ij} / [W_k H_k]_{ij}) [H_k^T]_{ji}}{\sum_j [H_k]_{kj}} \right) \\
&= [W_k]_{ik} \left(1 - \frac{\sum_j [H_k]_{kj} - \sum_j ([X]_{ij} / [W_k H_k]_{ij}) [H_k]_{kj}}{\sum_j [H_k]_{kj}} \right) \\
&= [W_k]_{ik} \left(\frac{\sum_j [H_k]_{kj} - (\sum_j [H_k]_{kj} - \sum_j ([X]_{ij} / [W_k H_k]_{ij}) [H_k]_{kj})}{\sum_j [H_k]_{kj}} \right) \\
&= [W_k]_{ik} \frac{\sum_j ([X]_{ij} / [W_k H_k]_{ij}) [H_k]_{kj}}{\sum_j [H_k]_{kj}}
\end{aligned}$$

También calculamos la expresión de actualización para H :

$$\begin{aligned}
[H_{k+1}]_{kj} &= [H_k]_{kj} - [t_H]_{kj} [\nabla_H f]_{kj} \\
&= [H_k]_{kj} - \frac{[H_k]_{kj}}{\sum_i [W_{k+1}]_{ik}} \left[W_{k+1}^T (\mathbf{1} - X \odot W_{k+1} H_k) \right]_{kj} \\
&= [H_k]_{kj} \left(1 - \frac{\sum_i [W_{k+1}^T]_{ki} (1 - [X]_{ij} / [W_{k+1} H_k]_{ij})}{\sum_i [W_{k+1}]_{ik}} \right) \\
&= [H_k]_{kj} \left(\frac{\sum_i [W_{k+1}]_{ik} - (\sum_i [W_{k+1}]_{ik} - \sum_i [W_{k+1}]_{ik} ([X]_{ij} / [W_{k+1} H_k]_{ij}))}{\sum_i [W_{k+1}]_{ik}} \right) \\
&= [H_k]_{kj} \frac{\sum_i [W_{k+1}]_{ik} ([X]_{ij} / [W_{k+1} H_k]_{ij})}{\sum_i [W_{k+1}]_{ik}}
\end{aligned}$$

▷ También tengo disponible la demostración de convergencia de las funciones de actualización, pero creo que puede alargar demasiado la subsección (ya larga de por sí)

Conclusión

En resumen, la Factorización No Negativa de Matrices (NMF) es una técnica que descompone la matriz término-documento no negativa X en el producto de dos matrices también no negativas, W y H , tal que $X \approx WH$. La clave de su utilidad en el clustering de documentos reside en la interpretación semántica de esta descomposición. La matriz W se interpreta como la matriz de tópicos, donde cada columna define un tema latente a través de los términos más relevantes del vocabulario. Por su parte, la matriz H funciona como una matriz de activaciones o pertenencia, indicando el grado en que cada documento se asocia con cada uno de los tópicos. Gracias a la restricción de no negatividad, los documentos se representan como una combinación aditiva de estos tópicos, un modelo conceptualmente intuitivo y fácil de interpretar.

El proceso de encontrar las matrices W y H óptimas se formula como un problema de optimización, donde el objetivo es minimizar una función de coste que mide la diferen-

cia entre la matriz original X y su aproximación WH . Se han presentado dos funciones principales, cada una con una justificación estadística: la distancia euclidiana (o norma de Frobenius), que equivale a asumir un ruido de tipo Gaussiano en los datos, y la divergencia de Kullback-Leibler (KL), que se deriva de un modelo de ruido de Poisson. La divergencia KL es a menudo preferida en el análisis de textos, ya que la distribución de Poisson es un modelo natural para datos de conteo, como las frecuencias de palabras.

Dado que el problema de optimización no es convexo, su solución se aborda mediante algoritmos iterativos. Los más extendidos son las reglas de actualización multiplicativa, que se han derivado para ambas funciones de coste. Estos algoritmos ajustan alternativamente W y H en cada iteración, con la propiedad fundamental de garantizar que las matrices resultantes siempre permanezcan no negativas, cumpliendo así con la restricción central del método. En última instancia, la NMF transforma la representación dispersa y de alta dimensionalidad de la matriz término-documento en una estructura de bajo rango y semánticamente rica, donde los documentos pueden ser agrupados eficazmente en función de su composición temática.

Podemos resumir esta subsección en la tabla 3.1.

Tabla 3.1.: Comparativa de las funciones de coste para NMF.

Aspecto	NMF con Distancia Euclidiana	NMF con Divergencia de K-L
Función de Coste	Minimizar $\ X - WH\ _F^2$	Minimizar $D_{KL}(X \ WH)$
Interpretación Estadística	Maximizar la verosimilitud asumiendo un ruido Gaussiano aditivo.	Maximizar la verosimilitud asumiendo un ruido de Poisson .
Tipo de Datos Ideal	Datos de valor real, donde el error se modela como una desviación simétrica en torno al valor real.	Datos de conteo (e.g., frecuencias de palabras). Es el enfoque estándar en análisis de texto.
Interpretación del Modelo	Geométrica: busca la mejor aproximación de X en el espacio euclidiano, minimizando la distancia.	Teoría de la Información: mide la divergencia entre la distribución empírica (X) y la del modelo (WH).
Reglas de Actualización	$W \leftarrow W \circ \frac{XH^T}{WHH^T}$ $H \leftarrow H \circ \frac{W^T X}{W^T WH}$	$W \leftarrow W \circ \frac{(X/WH)H^T}{\mathbf{1}H^T}$ $H \leftarrow H \circ \frac{W^T(X/WH)}{W^T \mathbf{1}}$
Consideración Práctica	Menos específico para la naturaleza estadística de los datos de texto. Puede ser sensible a outliers.	Generalmente conduce a resultados más dispersos y basados en partes, mejorando la interpretabilidad en clustering de documentos.

Nota: El símbolo $\circ$ denota el producto de Hadamard (elemento a elemento). La notación fraccionaria y la barra $'/'$ representan la división elemento a elemento. $\mathbf{1}$ es una matriz de unos con las dimensiones adecuadas.

3. *Métodos de clustering*

3.4. Mezcla de modelos

4. Validación

Parte II.

Aplicación informática

4.1. Estado del arte

4.1.1. Introducción

Durante las últimas décadas, la integración de sistemas informáticos en el ámbito educativo ha sido objeto de un intenso estudio, con el objetivo de ofrecer una enseñanza más personalizada, eficiente y de mayor calidad. Los Sistemas de Tutoría Inteligente (ITS, véase Glosario) han experimentado una evolución notable, pero es con la irrupción de la inteligencia artificial basada en modelos de lenguaje de gran tamaño (LLM, véase Glosario) cuando se alcanza un grado de personalización y adaptabilidad sin precedentes en la educación.

Este trabajo tiene como propósito analizar de manera rigurosa el estado actual de estas tecnologías y su impacto en el entorno educativo. Para ello, se definen en primer lugar los conceptos fundamentales (Sección 4.1.2), se presenta una perspectiva histórica sobre el desarrollo de los ITS, y se examinan implementaciones recientes de agentes conversacionales pedagógicos (CPA, véase Glosario) basados en LLM. Asimismo, se abordan tanto las oportunidades como los desafíos que plantean para la comunidad educativa, incluyendo una reflexión sobre los principios FATE (Fairness, Accountability, Transparency, Ethics; véase Glosario) en el desarrollo y aplicación de estas tecnologías.

4.1.2. Glosario de Términos

A continuación, se presenta un glosario de los términos fundamentales utilizados en este trabajo, organizados alfabéticamente para facilitar su consulta. Cada entrada incluye una definición clara y concisa, junto con referencias relevantes cuando sea necesario.

Agente Pedagógico Conversacional (CPA)

Sistemas interactivos que emplean diálogos en lenguaje natural para facilitar el aprendizaje. Como señalan Gulz et al. (2011) [41], estos agentes deben integrar dimensiones sociales, emocionales, cognitivas y pedagógicas para resultar efectivos en contextos educativos.

Análíticas de Aprendizaje (Learning Analytics)

Campo de estudio que se enfoca en la medición, recolección, análisis e informe de datos sobre los estudiantes y sus contextos, con el propósito de comprender y optimizar el aprendizaje y los entornos en los que este ocurre. Combina técnicas de minería de datos, análisis estadístico y modelado predictivo para mejorar los resultados educativos [9].

IA Basada en Datos

Enfoque de inteligencia artificial que extrae patrones y conocimiento a partir de grandes conjuntos de datos, utilizando técnicas de aprendizaje automático. Este paradigma contrasta con los sistemas basados en conocimiento explícito, ya que el conocimiento se deriva directamente de los datos de entrenamiento.

Modelo de Dominio (Domain Model)

Componente fundamental de un Sistema de Tutoría Inteligente que contiene el conocimiento experto sobre la materia que se está enseñando. Este modelo incluye conceptos, procedimientos, reglas y relaciones entre ellos, permitiendo al sistema

evaluar el conocimiento del estudiante y generar problemas y ejemplos relevantes. Su calidad es crucial para la efectividad pedagógica del sistema.

Modelo de Lenguaje Grande (LLM)

Arquitectura de procesamiento de lenguaje natural basada en redes neuronales profundas, entrenada con grandes volúmenes de datos textuales. Estos modelos, como GPT-4 o LLaMA, destacan por su capacidad para generar y comprender lenguaje natural de manera fluida y contextualizada [73].

Modelo del Estudiante (Learner Model)

Componente esencial de un ITS que representa el conocimiento, habilidades, preferencias y estado cognitivo del aprendiz. Este modelo se actualiza dinámicamente mediante la interacción del estudiante con el sistema, permitiendo la adaptación de la instrucción a las necesidades individuales [39].

Modelo Tutorial (Tutoring Model)

Componente de un Sistema de Tutoría Inteligente que determina las estrategias pedagógicas y las decisiones instruccionales. Este modelo decide cuándo y cómo intervenir, qué tipo de retroalimentación proporcionar, y cómo adaptar la instrucción al progreso del estudiante. Es responsable de implementar las teorías de aprendizaje y las estrategias didácticas en la interacción con el alumno.

Principios FATE

Marco ético que engloba cuatro pilares fundamentales en el desarrollo de sistemas de IA: Fairness (Equidad), Accountability (Responsabilidad), Transparency (Transparencia) y Ethics (Ética). Este marco resulta particularmente relevante en contextos educativos, donde las decisiones algorítmicas pueden tener un impacto significativo en el desarrollo de los estudiantes [19].

Procesamiento de Lenguaje Natural (NLP)

Área interdisciplinaria que combina lingüística, informática e inteligencia artificial para permitir la interacción entre humanos y máquinas mediante el lenguaje natural. Incluye tareas como análisis de sentimientos, traducción automática y generación de texto.

Prompt Engineering

Técnica de diseño y optimización de instrucciones (prompts) para guiar el comportamiento de los modelos de lenguaje. En el contexto educativo, implica formular preguntas y directrices de manera que los modelos generen respuestas pedagógicamente efectivas, precisas y adaptadas al nivel del estudiante. Esta habilidad es crucial para maximizar la utilidad educativa de los asistentes basados en IA.

Sistema Basado en Conocimiento

Sistema de inteligencia artificial que utiliza una base de conocimiento estructurado para resolver problemas complejos en dominios específicos, emulando el razonamiento de expertos humanos a través de reglas lógicas y mecanismos de inferencia.

Sistema de Tutoría Inteligente (ITS)

Sistema computacional que emula la capacidad de un tutor humano para propor-

cionar instrucción personalizada y retroalimentación adaptativa a los estudiantes. Según la arquitectura clásica propuesta por Sleeman y Brown (1982) [69], un ITS se compone de tres modelos fundamentales: el modelo del dominio (conocimiento experto), el modelo del estudiante y el modelo tutorial.

Esta terminología constituye la base conceptual sobre la que se asienta la presente investigación, proporcionando un marco de referencia común para la comprensión de los sistemas de tutoría inteligente y sus aplicaciones en el ámbito educativo.

4.1.3. Línea Histórica de los ITS




Figura 4.1.: Línea de tiempo que muestra los hitos clave en el desarrollo de los ITS desde sus inicios hasta la actualidad.

La evolución de los ITS refleja más de un siglo de innovación educativa, como se ilustra en la Figura 4.1. Este recorrido comienza en las primeras décadas del siglo XX con las máquinas de aprendizaje de Sidney Pressey y B.F. Skinner [15], dispositivos mecánicos que, aunque limitados, sentaron las bases conceptuales para la instrucción programada y el aprendizaje adaptativo.

El siguiente hito significativo llegó en la década de 1970 con el establecimiento de la arquitectura clásica de los ITS, que definió los tres modelos fundamentales: Dominio (Experto), Estudiante y Tutoría [69]. Este marco teórico encontró una de sus primeras implementaciones prácticas en SOPHIE (1974) [18], un sistema pionero que introdujo entornos de aprendizaje interactivos basados en simulación, permitiendo a los estudiantes experimentar con conceptos complejos en un entorno controlado y seguro.

El avance hacia sistemas más sofisticados se materializó en la década de 1990 con la aparición de tutores cognitivos como el Algebra Tutor [39]. Estos sistemas representaron un salto cualitativo al incorporar modelos cognitivos avanzados que permitían diagnosticar errores específicos de los estudiantes y ofrecer retroalimentación personalizada, acercándose así a la experiencia de un tutor humano.

El cambio de milenio trajo consigo la explosión de los MOOCs (Cursos Masivos Abiertos en Línea) y las analíticas de aprendizaje [9], marcando una transición hacia la educación digital a gran escala. Esta época se caracterizó por la recopilación masiva de datos educativos, lo que permitió el desarrollo de sistemas más sofisticados y adaptativos, capaces de ofrecer experiencias de aprendizaje personalizadas a miles de estudiantes simultáneamente.

El punto de inflexión más reciente en esta evolución llegó en 2017 con la arquitectura Transformer [73], que posibilitó el desarrollo de LLM como GPT-3. Estos sistemas representan un avance significativo en el campo del NLP, permitiendo interacciones más naturales

y contextualizadas. Con su capacidad sin precedentes para procesar y generar lenguaje natural de manera coherente, han dado lugar a una nueva generación de tutores inteligentes como Khanmigo y Duolingo Max. Estos sistemas representan un cambio de paradigma, pasando de tutores prescriptivos a asistentes conversacionales capaces de mantener diálogos naturales, ofrecer explicaciones detalladas y adaptarse dinámicamente a las necesidades individuales de cada estudiante.

La Figura 4.1 resume visualmente esta evolución, destacando cómo cada avance tecnológico ha ido ampliando las posibilidades de la educación asistida por computadora. Desde las primeras máquinas de enseñanza hasta los actuales asistentes de IA conversacional, la historia de los ITS es un testimonio de la búsqueda continua de formas más efectivas y accesibles de aprendizaje personalizado, un viaje que continúa evolucionando con cada avance tecnológico.

4.1.4. ChatGPT y la Necesidad de un Chatbot Educativo Específico

La irrupción de ChatGPT como exponente destacado de los LLM (véase Glosario) ha transformado la percepción social de la inteligencia artificial. Sin embargo, su aplicación directa en entornos educativos plantea desafíos significativos que requieren una reflexión profunda. Aunque su adopción es masiva entre estudiantes, a menudo sin supervisión docente [71], su naturaleza de propósito general lo hace inadecuado para contextos pedagógicos especializados.

Entre los principales desafíos se encuentran cuestiones éticas y de privacidad en el tratamiento de datos sensibles de estudiantes, así como un impacto significativo en el desarrollo del pensamiento crítico, según señalan estudios como [82]. La generación de contenido inexacto o sesgado [25] puede inducir a errores conceptuales difíciles de corregir, mientras que la ausencia de un verdadero Modelo del Estudiante (véase Glosario) limita su capacidad para ofrecer una experiencia educativa verdaderamente personalizada.

Pese a estas limitaciones, investigaciones como [82] han documentado mejoras en el rendimiento académico cuando se utiliza de forma guiada. Esta aparente paradoja subraya la necesidad de evolucionar hacia soluciones específicamente diseñadas para la educación, que vayan más allá de las capacidades de los modelos de lenguaje genéricos.

La transición desde herramientas como ChatGPT hacia verdaderos CPA requiere la implementación de un Modelo del Estudiante dinámico que evolucione con el aprendizaje del usuario, junto con una adhesión estricta a los Principios FATE. El desarrollo de capacidades avanzadas de NLP adaptadas al discurso educativo, junto con la integración de Sistemas Basados en Conocimiento, facilita la precisión y actualización constante de los contenidos.

Esta evolución no solo puede mejorar los resultados académicos, sino también transformar el rol docente. Los educadores podrán enfocarse en aspectos más estratégicos de la enseñanza, mientras los sistemas automatizados gestionan tareas rutinarias de seguimiento y evaluación. La sinergia entre la experiencia pedagógica humana y las capacidades de la inteligencia artificial representa el futuro de la educación personalizada y centrada en el estudiante, donde la tecnología actúa como un facilitador que potencia, en lugar de reemplazar, la labor del docente.

4.1.5. Agentes LLM para la Educación

Antes de profundizar en los chatbots educativos, veamos cómo [78] propone una estructura bastante sólida para definir los agentes basados en LLM. Para ello se definen 3 partes clave

de un agente LLM: El cerebro, la percepción y la acción.

- **Cerebro:** Es el núcleo central del agente, principalmente constituido por un LLM. Entre sus principales funciones se encuentran la generación y entendimiento del lenguaje natural, así como la capacidad de participar en una conversación interactiva. También necesita conocimiento, general y específico, de calidad y lo más actualizado posible; y memoria tanto de los *pensamientos* como de las acciones y observaciones del agente. Otra diferencia fundamental con hacer un uso básico de un LLM es el razonamiento, planificación y generalización, que dan lugar a respuestas más coherentes y a poder solucionar problemas complejos. El tamaño de la ventana de contexto de la LLM, así como la información y parámetros con la que ha sido entrenada son vitales para el buen funcionamiento del cerebro.
- **Percepción:** Es el sistema de entrada del agente, que le permite recibir información del entorno. Gracias a la multimodalidad de muchos LLMs hoy en día, el agente puede recibir información por varios medios. Esto significa que el agente puede recibir información basada en texto, pero también puede incluir imágenes, audio y otros tipos de datos, como pueden ser gestos, dispositivos vestibles, coordenadas...
- **Acción:** Es el sistema de salida del agente, que le permite interactuar con el entorno. Aunque tradicionalmente se ha asociado con la generación de texto, una capacidad clave de un agente es el uso de herramientas. Estas herramientas pueden incluir APIs, bases de datos, sistemas de control de dispositivos... Justo esta última herramienta da lugar a una línea de investigación interesante, la interacción de agentes LLM con el mundo real.

En conjunto, la definición estructurada de los agentes LLM —cerebro, percepción y acción— proporciona un marco conceptual claro para entender su funcionamiento y potencial en el ámbito educativo. Esta visión integral facilita la identificación de oportunidades y desafíos en su aplicación, sirviendo como base para analizar cómo estas capacidades se traducen en soluciones concretas, como los chatbots educativos, que se exploran en detalle a continuación.

La revolución de la arquitectura Transformer y la popularización de chatbots como ChatGPT han impulsado significativamente el desarrollo de los ITS, que, aunque llevan décadas evolucionando, han experimentado un avance sin precedentes en los últimos años. Este impulso ha trascendido el ámbito educativo, impactando también en áreas como la salud, la búsqueda de información y la industria [29, 50, 41].

La efectividad de estos sistemas se ve potenciada cuando se integran con fundamentos pedagógicos sólidos. Como señala [31], teorías como la Cognitiva Social, que enfatiza el aprendizaje a través de la observación y el modelado; la de Autodeterminación, que destaca la importancia de la autonomía del estudiante; y la Conductista, que subraya el valor de la retroalimentación inmediata, proporcionan un marco teórico valioso para el diseño de asistentes educativos.

Estos principios se manifiestan en características clave como la retroalimentación instantánea, la capacidad de modelar escenarios de aprendizaje personalizados [46], la adaptabilidad a las necesidades individuales de cada estudiante [47] y el uso del diálogo como herramienta pedagógica [14]. Aunque las diferentes teorías de base no siempre se mencionan explícitamente en las descripciones de los chatbots analizados, su presencia es fundamental para diferenciar un asistente educativo efectivo de un chatbot genérico como ChatGPT.

La integración de estas teorías pedagógicas con las capacidades avanzadas de los LLM representa una oportunidad única para desarrollar herramientas educativas verdaderamente transformadoras, capaces de ofrecer experiencias de aprendizaje personalizadas, accesibles y efectivas para estudiantes de todo el mundo.

4.1.5.1. Dominios de Aplicación Clave

Dentro del campo educativo, los chatbots basados en LLM han encontrado aplicaciones diversas, adaptándose a las necesidades específicas de cada disciplina.

Chatbots en Idiomas

El aprendizaje de idiomas ha sido uno de los campos más transformados por la irrupción de los LLM, que han permitido el desarrollo de chatbots conversacionales avanzados. Estas herramientas, basadas en NLP, ofrecen experiencias de aprendizaje personalizadas, interactivas y adaptativas, contribuyendo a la consolidación de los CPA en la educación de lenguas. Por ejemplo, [21] menciona chatbots que se centran en la práctica de la lectura, escritura, traducción y conversación.

Uno de los referentes más destacados es Duolingo, que integra chatbots impulsados por LLM para personalizar la experiencia de cada estudiante. Gracias a la analítica de datos y la modelización del estudiante (Learner Model), la plataforma puede predecir el momento óptimo de repaso, secuenciar contenidos, ajustar la dificultad de las lecciones y generar ejercicios personalizados [74]. Además, funcionalidades como los “Duolingo Stories” y las videollamadas aprovechan las capacidades de generación de texto y audio de los LLM para crear escenarios de comunicación atractivos y motivadores, todo ello en un entorno seguro y amigable [1].

Otro ejemplo paradigmático es Khanmigo, una aplicación online basada en IA generativa (GPT-4) que asiste a los estudiantes en el aprendizaje de idiomas mediante una interfaz conversacional. Entre sus funcionalidades destacan el repaso mediante preguntas cortas, la generación de temas para redacción, el debate con el bot y la posibilidad de interactuar con más de 90 personajes ficticios e históricos, lo que enriquece la práctica comunicativa y el contexto cultural. La retroalimentación instantánea y la personalización del diálogo contribuyen a una experiencia de aprendizaje más natural y efectiva [66].

La innovación no se limita a los entornos tradicionales: proyectos como ELLMA-T exploran la integración de LLM y realidad virtual para simular situaciones de aprendizaje inmersivas y contextuales. Estos Sistemas Basados en Conocimiento emplean los LLM para generar y evaluar dinámicamente los contenidos, adaptándose al progreso y necesidades del estudiante [54].

En síntesis, los chatbots en idiomas representan la convergencia de las tecnologías más avanzadas de IA, los principios de personalización y adaptabilidad educativa, y el potencial de los CPA para transformar la enseñanza de lenguas. Su desarrollo y evaluación requieren una integración rigurosa de los Principios FATE y un uso responsable de la Analítica de Aprendizaje, garantizando experiencias inclusivas, éticas y efectivas para todos los estudiantes.

Chatbots en Matemáticas

También en el ámbito de las matemáticas se han desarrollado varios chatbots [35], [77] y [44], aunque el enfoque debe ser diferente al de otras materias para atender a las particularidades de las matemáticas.

Estos chatbots tratan de paliar problemas de la enseñanza de las matemáticas, como el planteamiento e interpretación de problemas complejos y la necesidad de un razonamiento

lógico y estructurado para su resolución. Incluso dentro de las matemáticas, distintas áreas como el estudio de la geometría requieren de habilidades específicas, como la visualización espacial y la comprensión de conceptos abstractos [56, 28].

Además, son necesarios conjuntos de datos específicos [32, 36, 65] para poder usar técnicas de fine-tuning y así adaptar los modelos a las necesidades de la enseñanza de las matemáticas.

Un claro ejemplo de estas técnicas es [35], que para resolver problemas matemáticos complejos intercala razonamiento con generación y ejecución de código, lo que permite no solo obtener resultados precisos, sino también presentar un razonamiento paso a paso que facilita la comprensión de conceptos matemáticos complejos.

4.1.5.2. Ejemplos de Chatbots Educativos Recientes

Ejemplos de Chatbots que asisten al estudiante

El panorama actual de los CPA presenta una notable diversidad de enfoques y aplicaciones. Aunque la mayoría de las soluciones recientes se basan en LLM, es importante reconocer el trabajo pionero realizado con sistemas anteriores, como **AlgoBot** [34] y **CHATBOT** [50], que sentaron las bases para el desarrollo actual.

Estas herramientas destacan por su uso avanzado de prompt engineering para mejorar la interacción, junto con sistemas de dificultad adaptativa que se ajustan al ritmo del estudiante. Además, incorporan memoria a corto y largo plazo para permitir un seguimiento personalizado, integrando conocimiento específico del dominio educativo para ofrecer respuestas más precisas y contextualizadas.

En cuanto a la metodología de evaluación, el análisis de las implementaciones existentes revela que la mayoría de los estudios se basan en encuestas con muestras limitadas, en ocasiones con menos de 20 participantes. Sin embargo, algunas propuestas innovadoras, como las presentadas en [76] y [6], están explorando el uso de LLM para simular estudiantes, lo que permite realizar pruebas a mayor escala. Resulta particularmente interesante que solo en contadas excepciones, como en [23], se utilicen benchmarks estandarizados (C-Eval) para la evaluación, y que prácticamente no se encuentren estudios que hagan uso de herramientas de observabilidad para recopilar métricas objetivas.

Esta situación plantea interesantes oportunidades de investigación en el desarrollo de métricas objetivas y herramientas de análisis que complementen los métodos de evaluación tradicionales. La implementación de estos elementos permitiría una comprensión más completa del impacto real de estas tecnologías en el proceso educativo, facilitando la identificación de áreas de mejora y la optimización de las estrategias de enseñanza asistida por IA.

Nombre del Chatbot	Propósito Educativo	Características Clave	Método de Evaluación	Año
EduGPT	Ofrece asesoramiento educativo personalizado mediante chatbots especializados por materia y nivel.	Implementa una versión especializada de ChatGPT con agentes pre-configurados para contextos educativos específicos.	No especificada	-

Nombre del Chatbot	Propósito Educativo	Características Clave	Método de Evaluación	Año
AlgoBot [34]	Asiste a estudiantes en la asignatura de algorítmica de la Universidad de Oviedo.	Implementa un sistema basado en reglas con DialogFlow, ofreciendo respuestas predefinidas sin capacidades de lenguaje natural avanzado.	Encuesta (10 estudiantes)	2020
CHATBOT (Genérico) [50]	Proporciona respuestas educativas mediante el mapeo de palabras clave a una ontología de conocimiento.	Implementa un sistema de recuperación de información basado en reglas, utilizando procesamiento de lenguaje natural básico para la extracción de términos clave. No emplea modelos de lenguaje grandes.	Encuesta (187 estudiantes)	2018
Neurochat [11]	Adapta la experiencia de aprendizaje mediante el análisis de la actividad neuronal del estudiante usando dispositivos vestibles.	Implementa GPT-4 Turbo con un sistema de retroalimentación en tiempo real basado en métricas de compromiso cognitivo, integrando principios de neuroeducación.	Encuesta	2025
Iris [12]	Proporciona retroalimentación inmediata sobre ejercicios de programación en la plataforma Artemis.	Implementa un sistema de generación de respuestas utilizando Microsoft Guidance, con técnicas avanzadas como Chain-of-Thought y Few-Shot Learning para mejorar la precisión del feedback.	Encuesta (121 estudiantes)	2024
Educhat [23]	Ofrece tutoría personalizada en chino con evaluación de ensayos y soporte emocional.	Implementa un modelo de lenguaje con capacidades de RAG (Retrieval-Augmented Generation) y fine-tuning específico para educación, entrenado con libros de texto y conjuntos de datos de preguntas y respuestas.	Benchmark (C-Eval)	2023
ChatTutor [20]	Implementa un ciclo pedagógico de interacción, reflexión y reacción para el aprendizaje personalizado.	Emplea una arquitectura multi-agente con un módulo central que gestiona la memoria a corto y largo plazo, coordinando diferentes componentes especializados.	Encuesta (13 adultos)	2024

Nombre del Chatbot	Propósito Educativo	Características Clave	Método de Evaluación	Año
(Estudio de Prompts) [55]	Explora métodos para adaptar dinámicamente los prompts según el estado del estudiante.	Desarrolla un marco para ajustar automáticamente los estímulos de entrada basándose en el estado afectivo, nivel cognitivo y preferencias de aprendizaje del usuario.	Análisis cualitativo de diálogos	2024
MoodleBot [52]	Asiste a estudiantes dentro de la plataforma Moodle respondiendo dudas sobre los cursos.	Implementa un sistema de recuperación de información utilizando LangChain y LlamaIndex, con capacidades de seguimiento de costes y registro de interacciones.	Encuesta (30 estudiantes) y análisis de costes	2025
GenMentor [76]	Identifica brechas de habilidades y genera planes de aprendizaje personalizados.	Combina múltiples agentes de IA, incluyendo GPT-4 y Llama 3, con un sistema especializado en la detección de carencias formativas mediante análisis de competencias.	Evaluación automática (con GPT-4) y validación por expertos (n=20)	2024
Adaptative Tutor Agent [6]	Ajusta dinámicamente la dificultad de los problemas según el progreso del estudiante.	Implementa un sistema multi-agente que combina técnicas de ingeniería de prompts, recuperación de información (RAG) y modelado del estudiante para personalizar la experiencia de aprendizaje.	Pruebas con estudiantes simulados mediante IA	2025
IEC-V1 [58]	Prototipo desarrollado para un seminario sobre chatbots educativos.	Implementa un modelo Llama 3.1 8B mediante Ollama, con interfaz en Gradio, capacidades de procesamiento de documentos y ajuste automático de dificultad.	Encuesta en seminario (7 estudiantes)	2024

Cipherbot [63]	Plataforma link que usa recursos proporcionados por profesores para contestar las cuestiones de los alumnos. Proporciona un dashboard y analíticas para el profesorado.	Implementa un sistema de recuperación de información (RAG) con capacidades de búsqueda y generación de respuestas, adaptándose a los recursos educativos específicos del curso.	Análisis de uso del chatbot mediante logs de preguntas y respuestas, uso de documentos...	2024
----------------	---	---	---	------

Tabla 4.1.: Ejemplos de Chatbots en el ámbito de la docencia.

Ejemplos de Chatbots que asisten al profesor

Mientras que la sección anterior exploró cómo los chatbots basados en modelos de lenguaje grande (LLM) pueden asistir directamente a los estudiantes en su proceso de aprendizaje, esta subsección se enfoca en el creciente papel de estas herramientas como sistemas de apoyo para los educadores [42].

La integración de la inteligencia artificial y, en particular, de los chatbots impulsados por LLM, ofrece a los profesores la oportunidad de optimizar sus tareas diarias y mejorar sus prácticas pedagógicas [42, 25]. Estas tecnologías pueden automatizar funciones administrativas y repetitivas, como la resolución de preguntas frecuentes, la programación de actividades y la calificación de ejercicios, lo que libera tiempo valioso para que los docentes se centren en aspectos más complejos y personalizados de la enseñanza, como la planificación instruccional y la interacción directa con los estudiantes [42].

Trabajos como [28] sugieren usos como la creación de cuestionarios, evaluación del trabajo del estudiante, formación docente, generación y búsqueda de recursos educativos, facilitación del uso de otras herramientas educativas y generación de respuestas de ejercicios.

De este modo, los chatbots no solo transforman la experiencia del alumno, sino que también potencian la eficacia y la personalización de la labor docente.

Nombre	Función Principal	Características Técnicas	Evaluación	Año
Tutor Copilot [75]	Asiste a profesores durante sesiones de tutoría virtual.	Proporciona sugerencias contextuales en tiempo real para la gestión de pizarras digitales, chats y resolución de problemas. Incluye menú de acciones recomendadas.	Encuestas (700+ tutores, 1787 estudiantes)	2025
CGMI Framework [67]	Simula entornos educativos con múltiples agentes interactuando.	Implementa un sistema multi-agente con perfiles de personalidad diferenciados para estudiantes virtuales, permitiendo pruebas de escenarios educativos. Incluye módulos de razonamiento y planificación.	Análisis de interacción con Flanders (2 expertos)	2023

Nombre	Función Principal	Características Técnicas	Evaluación	Año
FreeText [49]	Genera retroalimentación automática para estudiantes basada en rúbricas.	Módulo Python integrable que analiza respuestas estudiantiles y genera comentarios personalizados según criterios del profesor. Incluye widgets para notebooks interactivos.	No especificada	2023
Sistema de Grafos [2]	Facilita la comunicación tutor-estudiante mediante recomendaciones basadas en grafos de conocimiento.	Implementa un sistema de filtrado de consultas, confirmación de intenciones y escalado a expertos humanos. Incluye capacidades de reprocesamiento de consultas.	Encuestas (182 estudiantes + 9 expertos)	2024
LLMAgent-CK [80]	Evalúa la alineación de las respuestas docentes con los objetivos de aprendizaje.	Emplea un sistema multiagente con roles especializados (Administrador, Juez, Crítico) que discuten y evalúan el contenido generado.	Pruebas con dataset MaCKT	2024

Tabla 4.2.: Ejemplos de Chatbots para Asistencia Docente.

4.1.6. Posibles Aportaciones de los Chatbots (ITS) a la Educación

Los ITS basados en chatbots ofrecen un amplio abanico de beneficios potenciales para estudiantes y educadores, como demuestran numerosos estudios recientes. Entre sus principales aportaciones destaca la capacidad de personalizar el aprendizaje mediante el Modelo Tutorial, ya que estos sistemas adaptan dinámicamente el ritmo, el estilo y el contenido de la enseñanza según el Modelo del Estudiante. Esta personalización ha demostrado mejoras de hasta un 30 % en los resultados de aprendizaje en plataformas como Khanmigo [4].

Otro aspecto fundamental es la retroalimentación inmediata y formativa, pues los sistemas proporcionan respuestas en tiempo real a las dudas de los estudiantes, detectando conceptos erróneos y ofreciendo explicaciones alternativas. Este enfoque ha permitido reducir en un 40 % el tiempo necesario para alcanzar competencias básicas en programación [4]. Además, el uso de técnicas de Procesamiento de Lenguaje Natural (NLP) en las interacciones contribuye a mantener niveles de atención hasta un 25 % más altos que en entornos tradicionales, lo que incrementa el compromiso estudiantil [4].

La disponibilidad ubicua de estos sistemas, accesibles 24/7, elimina barreras de tiempo y espacio, permitiendo a los estudiantes aprender a su propio ritmo y según sus necesidades específicas. Por otro lado, los docentes se benefician del apoyo que brindan los Sistemas Basados en Conocimiento, ya que pueden automatizar tareas rutinarias como la corrección de ejercicios o la resolución de dudas frecuentes. Esto les permite dedicar hasta un 35 % más de tiempo a la interacción personalizada con los estudiantes [42].

En cuanto a la transparencia pedagógica, los ITS muestran el proceso de razonamiento paso a paso, no solo resolviendo problemas, sino también modelando estrategias de pensamiento efectivas y alineándose con los Principios FATE de transparencia y explicabilidad

[45]. El análisis continuo de las interacciones permite, además, refinar el Modelo del Estudiante, ofreciendo una visión cada vez más precisa de sus fortalezas, debilidades y estilos de aprendizaje preferidos [72].

Finalmente, los CPA fomentan el desarrollo de habilidades metacognitivas, ayudando a los estudiantes a reflexionar sobre su propio aprendizaje y a desarrollar estrategias de autorregulación y pensamiento crítico. Se han documentado mejoras de hasta un 20 % en la retención de conceptos a largo plazo gracias a este enfoque [45].

Estas aportaciones, respaldadas por evidencia empírica, destacan el potencial transformador de los ITS en la educación, siempre que se implementen siguiendo principios pedagógicos sólidos y consideraciones éticas rigurosas.

4.1.7. Análisis del Aprendizaje

La sección de Learning Analytics (Análisis del Aprendizaje) es fundamental para comprender y optimizar el impacto de los chatbots de IA y los Sistemas de Tutoría Inteligente (ITS) en el ámbito educativo. Los Learning Analytics se definen como la medición, recopilación, análisis y presentación de datos sobre los estudiantes y sus contextos, con el objetivo de comprender y optimizar el aprendizaje y los entornos en los que ocurre [9, 45].

La proliferación de chatbots y LLM en la educación genera una gran cantidad de datos de interacción, que pueden ser aprovechados mediante Learning Analytics para ofrecer beneficios significativos a los educadores y mejorar la experiencia de aprendizaje en general. Entre las aportaciones clave de Learning Analytics en el contexto de los chatbots de IA para los educadores, se incluyen:

- **Profundización en la comprensión del estudiante:** El análisis de las interacciones con los chatbots permite construir un modelo del estudiante más preciso y detallado. Esto abarca el seguimiento del estado cognitivo del alumno, su nivel de conocimiento y progreso [55, 4], la detección de conceptos erróneos [72], y la identificación de las habilidades que necesita dominar para alcanzar sus objetivos [76]. Además, permite modelar los estados afectivos (emociones y actitudes como la motivación, el interés y la autoeficacia) [55, 76] y los estilos de aprendizaje preferidos, factores que son predictores del éxito académico y que impactan la eficacia de las metodologías de enseñanza [76].
- **Evaluación y mejora continua de la eficacia del chatbot:** El análisis del aprendizaje es esencial para validar la utilidad y el impacto pedagógico de los chatbots [41]. Se pueden utilizar para medir la precisión y congruencia de las respuestas generadas por el chatbot [52], el rendimiento del estudiante en ejercicios y evaluaciones [45, 50]. Por ejemplo, un estudio mostró que, aunque el sistema de tutoría implementado no garantizó mejoras significativas en el aprendizaje, el mecanismo de selección adaptativa de ejercicios operó según lo previsto, ajustando la dificultad al nivel de competencia de los estudiantes [55]. Estos datos son cruciales para la iteración y mejora del diseño del chatbot, permitiendo a los desarrolladores y educadores identificar si la herramienta está cumpliendo sus objetivos educativos o si es necesario un refinamiento en el enfoque de modelado del aprendizaje.
- **Apoyo a la personalización y adaptación del aprendizaje:** La capacidad de el análisis del aprendizaje para monitorear el progreso y las necesidades del estudiante en tiempo real permite a los ITS y chatbots adaptar dinámicamente los itinerarios de aprendizaje y el contenido [4, 76, 55]. Esto incluye la selección adaptativa de ejercicios con un nivel

de dificultad óptimo [55] y la generación de contenido personalizado según el nivel de conocimiento y lectura del alumno [76]. Este enfoque se traduce en una experiencia de aprendizaje más relevante y atractiva [47].

- **Optimización de las prácticas pedagógicas del docente:** Aunque los chatbots pueden automatizar tareas repetitivas como la calificación o la resolución de preguntas frecuentes, liberando tiempo al profesorado [21], el análisis del aprendizaje proporciona la información para que los docentes tomen decisiones informadas [38]. El análisis de las interacciones puede ayudar a los profesores a diseñar preguntas y criterios de calificación más efectivos [49].
- **Identificación de desafíos y problemáticas:** El análisis del aprendizaje es fundamental para detectar y cuantificar los riesgos asociados al uso de la IA en la educación. Esto incluye las “alucinaciones” (generación de información incorrecta o inventada por la IA), la presencia de sesgos en los datos de entrenamiento, el riesgo de dependencia excesiva de la tecnología, o el deterioro de habilidades cognitivas críticas como el pensamiento independiente y la resolución de problemas [82, 25]. Los datos permiten a desarrolladores y educadores comprender dónde y cómo los sistemas de IA no funcionan de manera óptima y si existe una falta de interacción humana [25].

En resumen, el análisis del aprendizaje actúa como el puente esencial entre la innovación tecnológica y la práctica pedagógica, capacitando a los educadores para comprender a fondo el proceso de aprendizaje mediado por la IA y para tomar decisiones basadas en datos que mejoren la calidad, personalización y equidad de la educación [9, 45].

4.1.8. Problemáticas y Desafíos en la Implementación de Agentes Pedagógicos Conversacionales

La implementación de CPA en educación presenta desafíos complejos y multidimensionales que requieren un enfoque integral. Estos retos afectan tanto a la tecnología como a la experiencia educativa, la ética y la transparencia del sistema.

4.1.8.1. Desafíos Técnicos y Pedagógicos

Entre los principales desafíos técnicos se encuentran las limitaciones del NLP, que dificultan la interpretación de matices no verbales y contextos sociales, así como la fiabilidad de los LLM, que pueden incurrir en “alucinaciones” o generación de información incorrecta. Estos problemas impactan directamente en la construcción de un Modelo del Estudiante preciso y en la calidad de la experiencia de aprendizaje. Además, la naturaleza de caja negra de los modelos más avanzados dificulta la explicabilidad y va en contra de los Principios FATE.

El coste de desarrollo y mantenimiento de los Sistemas Basados en Conocimiento puede ser prohibitivo, generando dependencia de soluciones comerciales y limitando la equidad en el acceso. Por otro lado, la excesiva automatización puede derivar en aislamiento social, pérdida de habilidades sociales o malos hábitos de aprendizaje, especialmente si el sistema no está bien supervisado o adaptado [2, 40, 13].

4.1.8.2. Barreras de Aceptación y Usabilidad

La literatura identifica barreras psicológicas, de compromiso, de percepción y de calidad de la interacción. Diversos estudios han señalado obstáculos clave que dificultan la aceptación y el uso efectivo de los sistemas conversacionales educativos.

En primer lugar, existen barreras de tipo psicológico, como la falsa sensación de anonimato, que puede inhibir la participación activa del estudiante y limitar la interacción abierta y sincera [27].

Por otro lado, las barreras relacionadas con el compromiso se manifiestan en el aburrimiento o la pérdida de interés tras la interacción inicial, lo que reduce la efectividad del sistema a largo plazo [68, 33].

A nivel de percepción, muchos usuarios consideran que la tecnología es inmadura o poco fiable, lo que genera desconfianza y reticencia a su uso [70]. Asimismo, en el plano de la interacción, el conocido “valle inquietante” provocado por algunos avatares puede resultar incómodo y afectar negativamente la experiencia [22].

En cuanto a la calidad, la frustración derivada de respuestas irrelevantes o repetitivas es frecuente y puede llevar al abandono del sistema [51]. Finalmente, desde una perspectiva ética, se identifican riesgos de sesgos y falta de empatía en las interacciones, lo que puede perpetuar desigualdades o generar experiencias negativas para ciertos colectivos [30, 31].

Estas barreras subrayan la importancia de considerar tanto los aspectos técnicos como los factores humanos y éticos en el diseño e implementación de agentes pedagógicos conversacionales.

4.1.8.3. Transparencia y Supervisión Ética

La transparencia es un imperativo ético fundamental. Según [19], existen tres niveles de transparencia:

- **Tier 1:** Investigadores con amplio conocimiento sobre Sistemas de IA.
- **Tier 2:** Ingenieros de software con cierto entendimiento sobre Sistemas de IA.
- **Tier 3:** Público general sin conocimiento experto sobre el tema.

Para clasificar un sistema de IA en los diferentes niveles, se evalúa la transparencia en el procesamiento de datos, los algoritmos utilizados, los modelos y los hiperparámetros, entre otros aspectos.

Para alcanzar los niveles 2 y 3, es necesario emplear métricas que permitan evaluar el sistema y estudiar los casos donde el sistema funciona bien y donde no. Además, se valora especialmente el papel de la persona en el propio sistema, quien debería tener un peso significativo en la toma final de decisiones.

La transparencia potencia la interpretabilidad, la explicabilidad y la responsabilidad, y requiere métricas rigurosas y supervisión humana en la toma de decisiones.

En síntesis, los desafíos en la implementación de agentes pedagógicos conversacionales son significativos, pero su identificación y análisis permiten avanzar hacia sistemas más efectivos, éticos y centrados en el estudiante.

A. Ejemplo de apéndice

Los apéndices son opcionales.

Este fichero `apendice-ejemplo.tex` es una plantilla para añadir apéndices al TFG. Para ello, es necesario:

- Crear una copia de este fichero `apendice-ejemplo.tex` en la carpeta `apendices` con un nombre apropiado (p.e. `apendice01.tex`).
- Añadir el comando `\input{apendices/apendice01}` en el fichero principal `tfg.tex` donde queremos que aparezca dicho apéndice (debe de ser después del comando `\appendix`).

Glosario

La inclusión de un glosario es opcional.

Archivo: `glosario.tex`

$\mathbb{R}$ Conjunto de números reales.

$\mathbb{C}$ Conjunto de números complejos.

$\mathbb{Z}$ Conjunto de números enteros.

Bibliografía

- [1] A. Abdallah, A. Alkaabi, D. Mehiar, and Z. Jaradat. *Chatbots in Classrooms: Tailoring Education and Boosting Engagement*, pages 166–181. 02 2024.
- [2] H. Abu-Rasheed, M. Abdulsalam, C. Weber, and M. Fathi. Supporting student decisions on learning recommendations: An llm-based chatbot with knowledge graph contextualization for conversational explainability and mentoring. 2024.
- [3] C. C. Aggarwal and C. Zhai. A survey of text clustering algorithms. In C. C. Aggarwal and C. Zhai, editors, *Mining Text Data*, pages 77–128. Springer, 2012.
- [4] Y. Akyuz. Effects of intelligent tutoring systems (its) on personalized learning (pl). *Creative Education*, 11:953–978, 2020.
- [5] J. Allan, J. Carbonell, G. Doddington, J. Yamron, and Y. Yang. Topic detection and tracking pilot study. In *Proceedings of the DARPA Broadcast News Transcription and Understanding Workshop*, pages 194–218. Morgan Kaufmann, 1998.
- [6] H. Almetnawy, A. Orabi, A. R. Alneyadi, T. Ahmed, and A. Lakas. An adaptive intelligent tutoring system powered by generative ai. In *2025 IEEE Global Engineering Education Conference (EDUCON)*, pages 1–10, London, United Kingdom, 2025.
- [7] A. Ang. Non-negative matrix factorization and multiplicative update. Technical report, Université de Mons (UMONS), Belgium, 2019. https://angms.science/doc/NMF/nmf_0.pdf.
- [8] D. Arthur and S. Vassilvitskii. k-means++: the advantages of careful seeding. In *SODA '07: Proceedings of the eighteenth annual ACM-SIAM symposium on Discrete algorithms*, pages 1027–1035, Philadelphia, PA, USA, 2007. Society for Industrial and Applied Mathematics.
- [9] P. Baeppler and C. Murdoch. Academic analytics and data mining in higher education. *International Journal for the Scholarship of Teaching and Learning*, 4, 2010.
- [10] P. B. Bafna, D. Pramod, and A. Vaidya. Document clustering: Tf-idf approach. *2016 International Conference on Electrical, Electronics, and Optimization Techniques (ICEEOT)*, pages 61–66, 2016.
- [11] D. Baradari, N. Kosmyna, O. Petrov, R. Kaplun, and P. Maes. Neurochat: A neuroadaptive ai chatbot for customizing learning experiences. 2025.
- [12] P. Bassner, E. Frankford, and S. Krusche. Iris: An ai-driven virtual tutor for computer science education. pages 394–400, 2024.
- [13] H. Bastani, O. Bastani, A. Sungu, H. Ge, Ö. Kabakçı, and R. Mariman. Generative ai can harm learning. 2024. The Wharton School Research Paper, Available at SSRN: <https://ssrn.com/abstract=4895486> or <http://dx.doi.org/10.2139/ssrn.4895486>.
- [14] R. Beale. Dialogic pedagogy for large language models: Aligning conversational ai with proven theories of learning, 2025.
- [15] L. T. Benjamin. A history of teaching machines. *American Psychologist*, 43(9):703–712, 1988.
- [16] J. C. Bezdek, R. Ehrlich, and W. Full. Fcm: The fuzzy c-means clustering algorithm. *Computers Geosciences*, 10(2):191–203, 1984.
- [17] H.-H. Bock. *Clustering Methods: A History of k-Means Algorithms*, pages 161–172. Springer Berlin Heidelberg, Berlin, Heidelberg, 2007.
- [18] J. S. Brown, R. R. Burton, and A. G. Bell. Sophie: A step toward creating a reactive learning environment. *International Journal of Man-Machine Studies*, 7(5):675–696, 1975.

- [19] M. Chaudhry, M. Cukurova, and R. Luckin. A transparency index framework for ai in education. 2022.
- [20] Y. Chen, N. Ding, H.-T. Zheng, Z. Liu, M. Sun, and B. Zhou. Empowering private tutoring by chaining large language models. pages 354–364, 2024.
- [21] Z. Chu, S. Wang, J. Xie, T. Zhu, Y. Yan, J. Ye, A. Zhong, H. Xuming, J. Liang, P. Yu, and Q. Wen. Llm agents for education: Advances and applications. 2025.
- [22] L. Ciechanowski et al. The uncanny valley in conversational agents: A mixed-methods study. *Future Generation Computer Systems*, 99:592–601, 2019.
- [23] Y. Dan, Z. Lei, Y. Gu, Y. Li, J. Yin, J. Lin, L. Ye, Z. Tie, Y. Zhou, Y. Wang, A. Zhou, Z. Zhou, Q. Chen, J. Zhou, L. He, and X. Qiu. Educhat: A large-scale language model-based chatbot system for intelligent education. 2023.
- [24] S. Deerwester, S. T. Dumais, G. W. Furnas, T. K. Landauer, and R. Harshman. Indexing by latent semantic analysis. *Journal of the American society for information science*, 41(6):391–407, 1990.
- [25] J. Dempere, K. Modugu, H. Allam, and L. Ramasamy. El impacto de chatgpt en la educación superior. *Frontiers in Education*, 8:1–13, 2023.
- [26] I. S. Dhillon and D. S. Modha. Concept decompositions for large sparse text data using clustering. In *Machine Learning*, pages 143–175, 2001.
- [27] M. e. a. Dibitonto. Chatbot in the classroom: a case study. In *Proceedings of the 13th International Conference on Interfaces and Human Computer Interaction*, 2018.
- [28] E. Dimitriadou and A. Lanitis. On The Potential of Using Generative Artificial Intelligence for Geometry Educational Activities. working paper or preprint, Apr. 2025.
- [29] L. Dong, Q. Lu, and L. Zhu. A taxonomy of agentops for enabling observability of foundation model based agents. 2024.
- [30] B. e. a. Eicher. Novelty and beyond: A study on student-chatbot interactions. *Journal of Educational Computing Research*, 60(3):567–593, 2022.
- [31] M. Ennion and R. McLellan. Large language model chatbots in education: Exploring literature insights on their impact and influence on learning behaviours. *Studies in Technology Enhanced Learning*, 4(1), 2025.
- [32] S. Frieder, L. Pinchetti, R.-R. Griffiths, T. Salvatori, T. Lukasiewicz, P. Petersen, A. Chevalier, and J. Berner. Mathematical capabilities of chatgpt. 01 2023.
- [33] L. K. Fryer et al. (a)cute boredom: A qualitative inquiry of four undergraduates’ experiences in a statistics course. *Instructional Science*, 45(2):173–193, 2017.
- [34] V. García Díaz, J. R. Pérez Pérez, C. González García, and V. Alvarez. Plataforma de asistencia virtual y automatizada para los alumnos de algoritmia mediante el empleo de un chatbot inteligente. 2021.
- [35] Z. Gou, Z. Shao, Y. Gong, Y. Shen, Y. Yang, M. Huang, N. Duan, and W. Chen. Tora: A tool-integrated reasoning agent for mathematical problem solving. 2023. arXiv preprint arXiv:2309.17452.
- [36] D. Hendrycks, C. Burns, S. Kadavath, A. Arora, S. Basart, E. Tang, D. Song, and J. Steinhardt. Measuring mathematical problem solving with the math dataset. 03 2021.
- [37] L. Kaufman and P. J. Rousseeuw. Clustering by means of medoids. *Statistical Data Analysis Based on the L1 Norm and Related Methods*, pages 405–416, 1987.
- [38] M. Kim, S. Kim, S. Lee, Y. Yoon, J. Myung, H. Yoo, H. Lim, J. Han, Y. Kim, S.-Y. Ahn, J. Kim, A. Oh, H. Hong, and T. Y. Lee. Llm-driven learning analytics dashboard for teachers in efl writing education, 2024.

- [39] K. R. Koedinger and A. Corbett. Cognitive tutors. In *Smart machines in education*, pages 145–167. 2001.
- [40] P. Kreijkes, V. Kewenig, M. Kuvalja, M. Lee, S. Vitello, J. Hofman, A. Sellen, S. Rintel, D. Goldstein, D. Rothschild, L. Tankelevitch, and T. Oates. Effects of llm use and note-taking on reading comprehension and memory: A randomised experiment in secondary schools. 2025.
- [41] M. Kuhail, N. Alturki, and S. e. a. Alramlawi. Interacting with educational chatbots: A systematic review. *Education and Information Technologies*, 28:973–1018, 2023.
- [42] L. Labadze, M. Grigolia, and L. Machaidze. Role of ai chatbots in education: systematic literature review. *International Journal of Educational Technology in Higher Education*, 20, 2023.
- [43] D. Lee and H. S. Seung. Algorithms for non-negative matrix factorization. In T. Leen, T. Dietterich, and V. Tresp, editors, *Advances in Neural Information Processing Systems*, volume 13. MIT Press, 2000.
- [44] B. Lei, Y. Zhang, S. Zuo, A. Payani, and C. Ding. Macm: Utilizing a multi-agent system for condition mining in solving complex mathematical problems. In *Advances in Neural Information Processing Systems*, volume 37, pages 53418–53437, 2025.
- [45] Q. Liu, J. Pinto, and L. Paquette. Applications of explainable ai (xai) in education. In *Explainable AI in Education*, page ? 2024.
- [46] R. Louie, A. Nandi, W. Fang, C. Chang, E. Brunskill, and D. Yang. Roleplay-doh: Enabling domain-experts to create llm-simulated patients via eliciting and adhering to principles. 06 2024.
- [47] S. Maity and A. Deroy. Generative ai and its impact on personalized intelligent tutoring systems. 2024.
- [48] C. D. Manning, P. Raghavan, and H. Schütze. *Introduction to Information Retrieval*. Cambridge University Press, Cambridge, UK, 2008.
- [49] J. Matelsky, F. Parodi, T. Liu, R. Lange, and K. Kording. A large language model-assisted education tool to provide feedback on open-ended responses. 2023.
- [50] M. L. Mohd Khidir and S. N. Sa’ari. Chatbot as an educational support system. *EPRA International Journal of Multidisciplinary Research (IJMR)*, pages 182–185, 2022.
- [51] G. Molnár and Z. Szűts. The role of chatbots in formal education. 2018.
- [52] A. T. Neumann, Y. Yin, S. Sowe, S. Decker, and M. Jarke. An llm-driven chatbot in higher education for databases and information systems. *IEEE Transactions on Education*, 68(1):103–116, Feb 2025.
- [53] P. Paatero and U. Tapper. Positive matrix factorization: A non-negative factor model with optimal utilization of error estimates of data values†. *Environmetrics*, 5:111–126, 1994.
- [54] M. Pan, A. Kitson, H. Wan, and M. Prpa. Ellma-t: an embodied llm-agent for supporting english language learning in social vr. <https://doi.org/10.48550/arxiv.2410.02406>, 2024. arXiv:2410.02406.
- [55] M. Park, S. Kim, S. Lee, S. Kwon, and K. Kim. Empowering personalized learning through a conversation-based tutoring system with student modeling. pages 1–10, 2024.
- [56] V. E. Parra, D. P. Sureda Figueroa, A. R. Corica, S. N. Schiaffino, and D. L. Godoy. Can generative AI solve Geometry problems? Strengths and weaknesses of LLMs for geometric reasoning in Spanish. *International Journal of Interactive Multimedia and Artificial Intelligence*, 8(1):65–74, feb 2024.
- [57] D. Peña. *Análisis de datos multivariantes*. McGraw-Hill, Madrid, 2002.
- [58] S. Pietrusky. Promoting ai literacy in higher education: Evaluating the iec-v1 chatbot for personalized learning and educational equity. 2024. [Preprint]. arXiv. <https://arxiv.org/abs/2412.16165>.
- [59] S. Pitafi, T. Anwar, and Z. Sharif. A taxonomy of machine learning clustering algorithms, challenges, and future realms. *Applied Sciences*, 13(6), 2023.

- [60] S. Qaiser and R. Ali. Text mining: Use of tf-idf to examine the relevance of words to documents. *International Journal of Computer Applications*, 2018.
- [61] N. Reimers and I. Gurevych. Sentence-bert: Sentence embeddings using siamese bert-networks. In *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing*. Association for Computational Linguistics, 11 2019.
- [62] D. Reinsel, J. Gantz, and J. Rydning. The digitization of the world: From edge to core. Technical report, IDC White Paper, 2018. US44413318.
- [63] J. Salminen, S.-g. Jung, J. Medina, K. Aldous, J. Azem, W. Akhtar, and B. J. Jansen. Using cipher-bot: An exploratory analysis of student interaction with an llm-based educational chatbot. In *Proceedings of the Eleventh ACM Conference on Learning @ Scale, L@S '24*, page 279–283, New York, NY, USA, 2024. Association for Computing Machinery.
- [64] G. Salton, A. Wong, and C.-S. Yang. A vector space model for automatic indexing. *Communications of the ACM*, 18(11):613–620, 1975.
- [65] P. Shakarian, A. Koyyalamudi, N. Ngu, and L. Mareedu. An independent evaluation of chatgpt on mathematical word problems (mwp). 02 2023.
- [66] S. Shetye. An evaluation of khanmigo, a generative ai tool, as a computer-assisted language learning app. *Studies in Applied Linguistics and TESOL*, 24, 07 2024.
- [67] J. Shi, J. Zhao, Y. Wang, X. Wu, J. Li, and L. He. Cgmi: Configurable general multi-agent interaction framework. *ArXiv*, 2023. abs/2308.12503.
- [68] K. Shu and T. Riki. The effect of chatbot personality on user boredom and engagement. *Computers in Human Behavior*, 118:106689, 2021.
- [69] D. Sleeman and J. S. Brown. *Intelligent Tutoring Systems*. Academic Press, London, 1982. 345 p.
- [70] P. Smutny and P. Schereiberova. Chatbots for learning: A review of educational chatbots for the facebook messenger. *Computers and Education*, 151:103862, 2020.
- [71] J. Sublime and I. Renna. Is chatgpt massively used by students nowadays? a survey on the use of large language models such as chatgpt in educational settings. 2024.
- [72] R. Suleman, R. Mizoguchi, and M. Ikeda. A new perspective of negotiation-based dialog to enhance metacognitive skills in the context of open learner models. *International Journal of Artificial Intelligence in Education*, 26:1069–1115, 2016.
- [73] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, and I. Polosukhin. Attention is all you need. In *Advances in Neural Information Processing Systems*, volume 30, 2017.
- [74] J. Vega, M. Rodriguez, E. Check, H. Moran, and L. Loo. Duolingo evolution: From automation to artificial intelligence. pages 1–6, 07 2024.
- [75] R. Wang, A. Ribeiro, C. Robinson, S. Loeb, and D. Demszky. Tutor copilot: A human-ai approach for scaling real-time expertise. 2024.
- [76] T. Wang, Y. Zhan, J. Lian, Z. Hu, N. Yuan, Q. Zhang, X. Xie, and H. Xiong. Llm-powered multi-agent framework for goal-oriented learning in intelligent tutoring system. 2025.
- [77] Y. Wu, F. Jia, S. Zhang, H. Li, E. Zhu, Y. Wang, Y. T. Lee, R. Peng, Q. Wu, and C. Wang. Math-chat: Converse to tackle challenging math problems with llm agents. 2023. arXiv preprint arXiv:2306.01337.
- [78] Z. Xi, W. Chen, X. Guo, W. He, Y. Ding, B. Li, W. Ruan, X. Xie, Z. Dou, E. Wang, et al. The rise and potential of large language model based agents: A survey. *arXiv preprint arXiv:2309.07864*, 2023.
- [79] X. Yan, J. Guo, Y. Lan, and X. Cheng. A biterm topic model for short texts. In *Proceedings of the 22nd International Conference on World Wide Web, WWW '13*, page 1445–1456, New York, NY, USA, 2013. Association for Computing Machinery.

- [80] K. Yang, Y. Chu, T. Darwin, A. Han, H. Li, H. Wen, Y. Copur-Gencturk, J. Tang, and H. Liu. Content knowledge identification with multi-agent large language models (llms). In *Artificial Intelligence in Education*, page ?, 2024.
- [81] L. Zadeh. Fuzzy sets. *Information and Control*, 8(3):338–353, 1965.
- [82] E. Çela, M. Fonkam, and R. M. Potluri. Risks of ai-assisted learning on student critical thinking:. *International Journal of Risk and Contingency Management*, 12:1–19, 2024.